



به نام خدا



دانشگاه تهران

دانشکده مهندسی برق و کامپیوتر

هوش مصنوعی قابل اعتماد

تمرین دوم

نام و نام خانوادگی	سید محمد جواد شریفی
شماره دانشجویی	۸۱۰۱۰۲۴۶۹
تاریخ ارسال گزارش	۱۴۰۵/۳/۴

3.....	سؤال اول: تفسیر پذیری
3.....	بخش اول: سوالات توضیحی
3.....	زیربخش اول: PDP
4.....	زیربخش دوم: Lime
4.....	زیربخش سوم: Shapley values
5.....	زیربخش چهارم: NAM
6.....	بخش دوم: سوالات پیاده‌سازی
6.....	زیربخش اول: مقداردهی مدل
6.....	زیربخش دوم: بخش‌بندی تصویر
7.....	زیربخش سوم: تولید نمونه‌های تغییر یافته
7.....	زیربخش چهارم: وزن‌دهی تصاویر تغییر یافته
8.....	زیربخش پنجم: آموزش مدل خطی
9.....	زیربخش ششم: تصویر خرس قطبی
11.....	سؤال دوم: توصیف‌پذیری مدل‌های هوش مصنوعی با استفاده از GRAD-CAM
11.....	بخش اول: GRAD-CAM
11.....	زیربخش اول: پرسش و پاسخ
13.....	زیربخش دوم: پیاده‌سازی
14.....	بخش دوم: FINERGRAD-CAM
14.....	زیربخش اول: پرسش و پاسخ
16.....	زیربخش دوم: پیاده‌سازی
17.....	بخش سوم: مقایسه
17.....	زیربخش اول: مقایسه دو روش
19.....	مراجع

سؤال اول: تفسیر پذیری

بخش اول: سوالات توضیحی

زیربخش اول: PDP

الف) اگر بین ویژگی‌های مجموعه S و ویژگی‌های مکمل C همبستگی زیادی وجود داشته باشد، در روش PDP مشکل ایجاد می‌شود؛ زیرا هنگام محاسبه PDP، مقادیر ویژگی‌های S به صورت مصنوعی تغییر داده می‌شوند اما مقادیر ویژگی‌های C از داده‌های واقعی هستند. در این حالت، اگر همبستگی میان دو مجموعه زیاد باشد ترکیب‌های جدیدی از ویژگی‌ها ساخته می‌شوند که در توزیع واقعی داده‌ها وجود ندارند و در واقع داده‌های عجیب و پرتی هستند. بنابراین مدل مجبور می‌شود برای نقاطی پیش‌بینی انجام دهد که در زمان آموزش مشاهده نکرده است و در نتیجه، خروجی‌های مدل نیز قابل اعتماد نخواهند بود. پس نمودار PDP بدست آمده نیز تفسیر درستی از مدل نخواهد داد.

ب) مشکل PDP این بود که ممکن بود ویژگی‌ها را به شکلی با هم ترکیب کند که آن ترکیب‌ها اصلاً در داده‌های واقعی وجود نداشته باشند.

ایده ALE این است که به جای این که اثر یک ویژگی را با ترکیب کردن آن با همه نمونه‌های داده بررسی کند، ابتدا اثر آن ویژگی را در بازه‌های کوچک و محلی محاسبه می‌کند. یعنی مثلاً اگر بخواهیم اثر سن را بررسی کنیم، فقط نمونه‌هایی را در نظر می‌گیرد که سنشان داخل یک بازه محدود است و بررسی می‌کند تغییر سن در همان بازه چه اثری روی خروجی مدل دارد. سپس این اثرهای محلی برای بازه‌های مختلف به صورت تجمعی با هم جمع می‌شوند تا اثر کلی آن ویژگی به دست بیاید.

چون ALE از نواحی محلی استفاده می‌کند، داده‌های تولیدی توسط آن کمتر وارد ترکیب‌های غیرواقعی می‌شوند و در نتیجه وقتی بین ویژگی‌ها همبستگی وجود داشته باشد، معمولاً تفسیر دقیق‌تر و قابل اعتمادتری نسبت به PDP می‌دهد.

ج) خیر. نمیتوان چنین نتیجه‌ای گرفت. نمودار PDP میانگین اثر ویژگی X_1 را روی پیش‌بینی مدل نشان می‌دهد. یعنی ممکن است اثر X_1 برای برخی نمونه‌ها مثبت و برای بعضی دیگر منفی باشد ولی میانگین این آثار ۰ باشد و بنابراین PDP به صورت خط صاف دیده شود. اما این به این معنا نیست که مدل در پیش‌بینی‌اش از ویژگی X_1 استفاده نمی‌کند.

زیربخش دوم: Lime

چون LIME برای هر نمونه یک تقریب خطی محلی فیت می‌کند، در شرایطی ممکن است که این تقریب گمراه‌کننده باشد. اگر مدل جعبه‌سیاه در نزدیکی یک نمونه رفتار خیلی ناپایدار یا ناهموار داشته باشد، یک مدل خطی محلی می‌تواند گمراه‌کننده باشد؛ حتی اگر همسایگی را خیلی کوچک انتخاب کنیم.

در واقع در شرایطی که با تغییر بسیار کم در ورودی، خروجی مدل به شدت تغییر کند یا مرز تصمیم مدل در یک ناحیه خیلی پیچیده باشد، مدل خطی نمی‌تواند رفتار واقعی مدل را به درستی تفسیر کند. در چنین حالتی، علی‌رغم اینکه می‌توان یک تقریب خطی ساده و قابل فهم برای یک نمونه بدست آورد اما این تقریب خطی تفسیر درستی برای آن نمونه ارائه نمی‌دهد.

این موضوع به مفهوم Lipschitz بودن مدل هم مربوط است. اگر مدل Lipschitz باشد، یعنی تغییرات کوچک در ورودی باعث تغییرات خیلی بزرگ و ناگهانی در خروجی نمی‌شود. در این حالت تقریب خطی محلی قابل اعتمادتر است. اما اگر مدل Lipschitz نباشد، مدل ممکن است در یک ناحیه کوچک هم رفتار تند و ناپایدار داشته باشد و در نتیجه تقریب خطی محلی LIME می‌تواند اشتباه یا گمراه‌کننده شود.

زیربخش سوم: Shapley values

الف) مقدار shapley برای ویژگی z در یک نمونه خاص، نشان می‌دهد که این ویژگی چه سهمی در اختلاف خروجی مدل برای آن نمونه نسبت به میانگین خروجی مدل روی کل داده‌ها دارد.

با توجه به تعریف $f(x)$ ، سهم ویژگی z در خروجی برابر $\beta_z x_z$ می‌باشد. از طرف دیگر، سهم متوسط این ویژگی روی کل داده‌ها برابر $\beta_z(\mathbb{E}[X_z])$ است. پس سهم این ویژگی نسبت به حالت متوسط برابر اختلاف این دو مقدار خواهد بود:

$$\beta_z x_z - \beta_z(\mathbb{E}[X_z]) = \beta_z(x_z - \mathbb{E}[X_z])$$

و این همان مقدار Shapley برای ویژگی z و در یک نمونه خاص مانند i است.

ب) با توجه به نتیجه بخش قبل، یک ایده ساده برای تقریب Shapley در مدل‌های جعبه‌سیاه این است که به جای محاسبه دقیق Shapley برای همه ترکیب‌های ممکن ویژگی‌ها (که از اردر نمایی بر حسب تعداد ویژگی است)، فرض کنیم که مدل در اطراف یک نمونه خاص، تقریباً رفتار خطی دارد و رفتار مدل در همسایگی آن نمونه را به صورت خطی تقریب بزنیم. در این صورت می‌توانیم ضریب متناظر با هر ویژگی و همچنین میانگین آن ویژگی را بدست آوریم و با استفاده از فرمول قسمت الف، مقدار Shapley آن را تخمین بزنیم.

NAM یک مدل جمع‌پذیر عصبی است. در این معماری، برای هر ویژگی ورودی یک شبکه عصبی جداگانه در نظر گرفته می‌شود. یعنی هر ویژگی x_j وارد شبکه مخصوص خودش می‌شود و آن شبکه یک تابع یک‌متغیره مثل $f_j(x_j)$ را یاد می‌گیرد. در نهایت خروجی همه این شبکه‌ها با هم جمع می‌شوند و خروجی نهایی مدل ساخته می‌شود. بنابراین فرم کلی مدل شبیه مدل‌های جمع‌پذیر است، با این نکته که توابع مربوط به ویژگی‌ها توسط شبکه‌های عصبی یاد گرفته می‌شوند.

این معماری به تفسیرپذیری کمک می‌کند، چون اثر هر ویژگی مستقل از بقیه ویژگی‌ها قابل مشاهده است. برای هر ویژگی می‌توان نمودار $f_j(x_j)$ را رسم و بررسی کرد که با تغییر آن ویژگی، خروجی مدل چگونه تغییر می‌کند. نکته مهم این است که این نمودارها فقط یک توضیح تقریبی نیستند، بلکه دقیقاً همان چیزی را نشان می‌دهند که مدل برای محاسبه خروجی استفاده می‌کند. به همین دلیل NAM یک مدل ذاتاً قابل تفسیر محسوب می‌شود.

مزیت اصلی NAM نسبت به مدل خطی این است که می‌تواند رابطه‌های غیرخطی بین هر ویژگی و خروجی را یاد بگیرد. در مدل خطی فرض می‌شود اثر هر ویژگی روی خروجی یک خط مستقیم است، اما در داده‌های واقعی ممکن است اثر یک ویژگی پیچیده‌تر باشد. NAM می‌تواند این شکل‌های پیچیده را یاد بگیرد، در حالی که هنوز اثر هر ویژگی به صورت جداگانه قابل رسم و تفسیر است.

محدودیت اصلی NAM این است که اثر ویژگی‌ها را به صورت جدا از هم مدل می‌کند و تعامل‌های پیچیده بین ویژگی‌ها را به طور مستقیم در نظر نمی‌گیرد. یعنی اگر اثر یک ویژگی به شدت به مقدار ویژگی دیگر وابسته باشد، ممکن است نتواند این رابطه را به خوبی مدل کند. البته می‌توان interaction ها را به مدل اضافه کرد، اما این کار تفسیرپذیری مدل را سخت‌تر می‌کند.

در مورد مشکل PDP، می‌توان گفت که NAM این مشکل را کاهش می‌دهد. چون برای فهمیدن اثر یک ویژگی دیگر لازم نیست مثل PDP مقدار آن ویژگی را با همه مقادیر ممکن سایر ویژگی‌ها ترکیب کنیم. در NAM، اثر هر ویژگی مستقیماً از تابع یادگرفته‌شده مربوط به همان ویژگی به دست می‌آید. بنابراین مدل برای توضیح دادن اثر ویژگی مجبور نیست روی ترکیب‌های غیرواقعی از داده‌ها میانگین‌گیری کند.

بخش دوم: سوالات پیاده‌سازی

زیربخش اول: مقداردهی مدل


کد این بخش در فایل q1.ipynb در فلدر Q1 موجود است و نتیجه به صورت زیر بدست آمده است:

```
Probability of belonging to the cat class: 0.91
```

شکل ۱: احتمال تعلق تصویر به کلاس گربه

زیربخش دوم: بخش‌بندی تصویر

کد این بخش در فایل q1.ipynb در فلدر Q1 موجود است و نتیجه به صورت زیر بدست آمده است:



شکل ۲: بخش‌بندی تصویر

در مورد نحوه بخش‌بندی تابع `kmeans_segment` می‌توان گفت که این تابع، تصویر را در ابتدا به ویژگی‌های هر پیکسل تبدیل می‌کند؛ این ویژگی‌ها شامل رنگ (RGB) و مختصات مکانی پیکسل هستند. هدف از این کار این است که اطلاعات رنگ و موقعیت، همزمان در بخش‌بندی لحاظ شوند. سپس الگوریتم KMeans این پیکسل‌ها را در n خوشه گروه‌بندی می‌کند، به طوری که پیکسل‌های مشابه در رنگ و موقعیت مکانی، در یک خوشه قرار می‌گیرند.

در نهایت یک آرایه دوبعدی تولید می‌شود که عدد هر خانه نشان‌دهنده segment مربوط به آن پیکسل است و در نتیجه تصویر به نواحی هم‌رنگ و نزدیک به هم تقسیم می‌شود، که برای تولید تصاویر تغییر یافته در مراحل بعدی استفاده می‌شود.

زیربخش سوم: تولید نمونه‌های تغییر یافته

کد این بخش در فایل q1.ipynb در فلدر Q1 موجود است و نتیجه به صورت زیر بدست آمده است:



شکل ۳: نمونه‌هایی از تصاویر تغییر یافته

زیربخش چهارم: وزن‌دهی تصاویر تغییر یافته

کد این بخش در فایل q1.ipynb در فلدر Q1 موجود است.


وزن‌دهی نمونه‌های تغییر یافته به این منظور انجام می‌شود که نمونه‌هایی که شباهت بیشتری به تصویر اصلی دارند، در آموزش مدل اهمیت بیشتری پیدا کنند. (با توجه به فرمول گفته شده برای وزن، هر چه $dist(z)$ کمتر باشد، وزن بیشتر می‌شود.) به این ترتیب، مدل خطی هنگام یادگیری، روی نمونه‌های نزدیک به تصویر اصلی تمرکز بیشتری می‌کند و بنابراین تفسیری هم که از نتایج مدل بدست می‌آید با تصویر اصلی مطابقت بیشتری دارد و قابل اعتمادتر خواهد بود.

زیربخش پنجم: آموزش مدل خطی

کد این بخش در فایل q1.ipynb در فلدر Q1 موجود است.

در روش LIME، استفاده از L1 Regularization مفید است زیرا باعث می‌شود بسیاری از ضرایب ویژگی‌های کم‌اهمیت مدل به صفر یا نزدیک صفر برسند. علت این اتفاق در این است که در L1 Regularization، مقدار جریمه متناسب با مقدار ضرایب مدل است؛ به عبارتی هرچه ضرایب بزرگ‌تر باشند، مقدار جریمه بیشتر می‌شود. این ویژگی باعث می‌شود که بسیاری از ضرایب ویژگی‌های کم‌اهمیت به صفر یا نزدیک صفر برسند و تنها بخش‌های واقعاً مهم تصویر باقی بمانند. در نتیجه توضیح مدل ساده‌تر و قابل‌تفسیرتر می‌شود، چرا که فقط نواحی‌ای که بیشترین اثر را روی تصمیم مدل دارند مشخص می‌شوند و نویزها یا بخش‌های کم‌اهمیت حذف می‌شوند. در واقع، استفاده از L1 به مدل کمک می‌کند تمرکزش روی مهم‌ترین بخش‌ها باشد و heatmap نهایی واضح‌تر و قابل‌فهم‌تر شود.

نتیجه این بخش به صورت زیر بدست آمده است:



شکل ۴: نمودار heatmap اهمیت بخش‌های تصویر گربه

در تحلیل این heatmap می‌توان گفت که بخش‌های تصویر که رنگ آبی پررنگ دارند نشان می‌دهند که حضور آن ناحیه‌ها به شدت احتمال پیش‌بینی مدل برای کلاس هدف (گربه) را افزایش می‌دهد. به عبارت دیگر، مدل بیشتر به این نواحی توجه کرده است تا تصمیم بگیرد تصویر متعلق به کلاس گربه است. همچنین می‌توان گفت که بخش‌های روشن‌تر یا نزدیک به سفید اثر کمتری در تصمیم‌گیری مدل دارند و


بخش‌های قرمز (اگر وجود داشته باشند) مناطقی هستند که حضورشان باعث کاهش احتمال پیش‌بینی کلاس گربه می‌شود.

در تصویر ارائه‌شده، مشاهده می‌کنیم که مهم‌ترین بخش‌ها تقریباً روی بدن و سر گربه متمرکز شده‌اند و پس‌زمینه یا بخش‌هایی که خارج از گربه هستند، اهمیت چندانی ندارند.

این تحلیل نشان می‌دهد که مدل برای تشخیص گربه، بیشتر روی خود حیوان تمرکز کرده و بخش‌های غیرمهم تصویر تأثیر کمی در تصمیم‌گیری داشته‌اند، که نتیجه‌ای منطقی و قابل تفسیر است.

زیربخش ششم: تصویر خرس قطبی

کد این بخش در فایل `q1.ipynb` در فلدر `Q1` موجود است و نتیجه به صورت زیر بدست آمده است:



شکل ۵: نمودار heatmap اهمیت بخش‌های تصویر خرس قطبی

در تحلیل این heatmap می‌توان گفت که بخش‌های تصویر که رنگ آبی پررنگ دارند نشان می‌دهند که حضور آن ناحیه‌ها به شدت احتمال پیش‌بینی مدل برای کلاس هدف (خرس قطبی) را افزایش می‌دهد. به عبارت دیگر، مدل بیشتر به این نواحی توجه کرده است تا تصمیم بگیرد تصویر متعلق به کلاس خرس قطبی است. همچنین می‌توان گفت که بخش‌های روشن‌تر یا نزدیک به سفید اثر کمتری در تصمیم‌گیری مدل دارند و بخش‌های قرمز (اگر وجود داشته باشند) مناطقی هستند که حضورشان باعث کاهش احتمال پیش‌بینی کلاس خرس قطبی می‌شود.

در تصویر ارائه شده، مشاهده می‌کنیم که مهم‌ترین بخش‌ها عمدتاً روی پشت و سر خرس قطبی متمرکز هستند و نکته جالب این است که قسمت جلوی بدن خرس قطبی، توجه مدل را جلب نکرده است. (ممکن است به خاطر شباهت این قسمت از بدن او با سایر کلاس‌ها باشد!)

همچنین در مقایسه این heatmap با heatmap قبلی می‌توان به این نکته اشاره کرد که برخلاف تصویر گربه، برخی نواحی پس‌زمینه مانند زمین و برف نیز ضریب مثبت دارند و توجه مدل را جلب کرده‌اند. به عبارت دیگر، مدل علاوه بر ویژگی‌های حیوان، از اطلاعات محیط اطراف نیز برای تشخیص کلاس استفاده کرده است.

این مقایسه با تصویر گربه نشان می‌دهد که در مورد گربه توجه مدل تقریباً کاملاً روی خود حیوان است و پس‌زمینه نقش چندانی ندارد، اما در مورد خرس قطبی، محیط اطراف (مانند برف و زمین) به عنوان شاخص‌های کمکی اهمیت بیشتری دارند. بنابراین مدل برای هر تصویر با توجه به ویژگی‌های محیط طبیعی حیوان، تمرکز متفاوتی روی حیوان و پس‌زمینه دارد و تصمیم‌گیری آن منطقی و قابل تفسیر است.

سوال دوم: توصیف‌پذیری مدل‌های هوش مصنوعی با استفاده از GRAD-CAM

بخش اول: GRAD-CAM

زیربخش اول: پرسش و پاسخ

(۱) نویسندگان مقاله بیان می‌کنند که Grad-CAM یک تعمیم از CAM است، زیرا همان ایده اصلی CAM را به معماری‌های بسیار گسترده‌تری از شبکه‌های CNN گسترش می‌دهد. CAM تنها روی شبکه‌هایی قابل استفاده است که در آن‌ها feature map های کانولوشنی پس از Global Average Pooling مستقیماً به لایه طبقه‌بندی خطی و بعد به لایه softmax متصل شوند و بنابراین وجود چند لایه fully-connected یا ساختارهای پیچیده‌تر باعث می‌شود CAM قابل استفاده نباشد. در مقابل، Grad-CAM با استفاده از گرادیان‌های مربوط به کلاس هدف نسبت به feature map های لایه کانولوشنی، وزن اهمیت هر feature map را محاسبه می‌کند و بنابراین بدون تغییر معماری و بدون نیاز به آموزش مجدد، روی مدل‌های مختلفی مانند VGG، ResNet، image captioning و VQA قابل اعمال است. مقاله همچنین به صورت ریاضی اثبات می‌کند که در معماری‌های مبتنی بر Global Average Pooling، وزن‌های CAM یعنی w_k^c با وزن‌های Grad-CAM یعنی α_k^c معادل می‌شوند و در نتیجه CAM حالت خاصی از Grad-CAM است.

پیامد عملی مهم این تعمیم این است که Grad-CAM برخلاف CAM نیاز ندارد معماری شبکه را عوض کند یا مدل را دوباره آموزش دهد. به همین دلیل می‌توان آن را روی مدل‌های آماده و موجود به کار برد؛ مثلاً شبکه‌هایی که لایه‌های fully-connected دارند، مدل‌های captioning، مدل‌های Visual Question Answering و حتی معماری‌هایی مثل ResNet. این باعث می‌شود Grad-CAM بدون قربانی کردن دقت مدل یا تغییر ساختار آن، تفسیرپذیری را به طیف بزرگ‌تری از مدل‌های CNN اضافه کند.

(۲) نویسندگان در ترکیب نهایی نقشه‌های فعال‌سازی از ReLU استفاده می‌کنند، چون در Grad-CAM هدف این است که فقط نواحی‌ای نشان داده شوند که برای کلاس مورد نظر اثر مثبت دارند؛ یعنی قسمت‌هایی از تصویر که وجود آن‌ها باعث افزایش امتیاز آن کلاس می‌شود. به همین دلیل بعد از ترکیب وزن‌دار feature map ها، مقادیر منفی حذف می‌شوند؛ چرا که طبق توضیح مقاله این نواحی منفی احتمالاً به کلاس‌های دیگر تصویر مربوط‌اند و نه به کلاس هدف. اگر ReLU حذف شود، نقشه‌ی نهایی ممکن است علاوه بر نواحی مربوط به کلاس مورد نظر، بخش‌هایی از تصویر را هم برجسته کند که در واقع به کلاس‌های دیگر یا شواهد مخالف آن کلاس مربوط هستند؛ در نتیجه localization ضعیف‌تر و کمتر دقیق می‌شود. بنابراین استفاده از ReLU نشان می‌دهد که گرادیان‌های مثبت بیانگر شواهد پشتیبان کلاس هدف هستند،

در حالی که گرادیان‌های منفی بیشتر نشان‌دهنده‌ی ویژگی‌هایی هستند که امتیاز آن کلاس را کاهش می‌دهند یا به کلاس‌های دیگر ارتباط دارند.


۳) نویسندگان برای نشان دادن توانایی Grad-CAM در کشف bias، یک مدل VGG-16 از پیش‌آموزش‌دیده را برای طبقه‌بندی دو کلاس doctor و nurse، finetune کردند و داده‌های آموزش و اعتبارسنجی را از نتایج یک موتور جست‌وجوی تصویر ساختند. آنها مجموعه‌ی آزمون را از نظر جنسیت متعادل نگه داشتند. با اینکه مدل روی مجموعه اعتبارسنجی خوب عمل می‌کرد، روی مجموعه آزمون عملکرد ضعیف‌تری داشت. وقتی نویسندگان با Grad-CAM تصمیم‌های مدل را بررسی کردند، دیدند مدل برای تشخیص دکتر و پرستار بیشتر به صورت و مدل مو توجه می‌کند؛ نه به نشانه‌های واقعی‌تر مثل روپوش سفید، گوشی پزشکی یا لباس پرستاری. این بررسی‌ها نشان داد که داده‌های آموزشی سوگیری جنسیتی داشته‌اند؛ چرا که بیشتر تصاویر doctor مرد و بیشتر تصاویر nurse زن بودند. بعد از این مشاهده، آن‌ها با اضافه کردن تصاویر پرستاران مرد و پزشکان زن، سوگیری داده را کاهش دادند و در نتیجه مدل جدید به نواحی مهم‌تر و اساسی‌تر تصویر توجه بیشتری می‌کرد و دارای دقت بهتری شد. اهمیت این موضوع فقط مربوط به بعد فنی نیست، چرا که مدل‌های آموزش‌دیده روی داده‌های سوگیرانه، ممکن است در دنیای واقعی تعمیم خوبی نداشته باشند و همچنین فاکتورایی مثل جنسیت، نژاد یا سن را در تصمیم‌گیری‌های خود بیش از اندازه اولویت دهند که این موضوع به دور از عدالت و اصول اخلاقی است.

۴) علت معرفی روش Guided Grad-CAM توسط نویسندگان این است که Grad-CAM هرچند می‌تواند نواحی مربوط به کلاس هدف را به شکل متمایز از سایر کلاس‌ها مشخص کنید (یعنی class-discriminative است)، اما ناحیه‌ای که در heatmap مشخص می‌کند نسبتاً بزرگ است و نمی‌تواند جزئیات مورد توجه مدل را به خوبی نشان دهد. از طرف دیگر، روش‌هایی مثل Guided Backpropagation جزئیات تصویری را با وضوح بالا نشان می‌دهند اما class-discriminative نیستند؛ یعنی برای کلاس‌های مختلف heatmap‌های نسبتاً مشابه تولید می‌کنند و دقیقاً مشخص نمی‌کنند که کدام جزئیات مربوط به کدام کلاس است. بنابراین نویسندگان این دو روش را با ضرب نقطه به نقطه ترکیب می‌کنند. ابتدا نقشه‌ی Grad-CAM را به اندازه‌ی تصویر اصلی بزرگ می‌کنند و سپس آن را با خروجی Guided Backpropagation ترکیب می‌کنند. نتیجه‌ی این ترکیب، Guided Grad-CAM است که هم وضوح بالا و جزئیات ریز مورد توجه مدل را دارد و هم class-discriminative است؛ مثلاً برای کلاس tiger cat نه فقط ناحیه‌ی گربه، بلکه ویژگی‌های مهمی مثل راه‌راه بودن، گوش‌های نوک‌تیز و چشم‌ها را نشان می‌دهد، بدون اینکه نواحی مربوط به کلاس دیگر مثل سگ را برجسته کند.

زیربخش دوم: پیاده‌سازی


الف و ب) کد این دو بخش در فایل q2.ipynb در فلدر Q2 موجود است.

ج) کد این بخش در فایل q2.ipynb در فلدر Q2 موجود است و نتیجه به صورت زیر بدست آمده است:



شکل ۶: نمونه‌هایی از Saliency map های ایجاد شده توسط Grad-CAM

د) کد این بخش در فایل q2.ipynb در فلدر Q2 موجود است و نتیجه به صورت زیر بدست آمده است:



شکل ۷: نمونه map های ایجاد شده توسط Grad-CAM و Guided-Grad-CAM

(۱) نویسندگان می‌گویند مشکل Grad-CAM در طبقه‌بندی‌های fine-grained بیشتر به «چه چیزی توضیح داده می‌شود» مربوط است، نه به «چگونه توضیح داده می‌شود». منظور این است که Grad-CAM معمولاً فقط کلاس هدف را به‌تنهایی توضیح می‌دهد و قسمت‌هایی را نشان می‌دهد که امتیاز همان کلاس را زیاد می‌کنند؛ اما در موارد fine-grained، کلاس‌ها خیلی شبیه به هم هستند و بسیاری از ویژگی‌هایی که برای کلاس هدف اهمیت دارند، برای کلاس‌های مشابه هم مهم هستند. مثلاً در مقاله گفته می‌شود Blue Grosbeak و Grandala ویژگی‌های بدنی مشترکی دارند و وقتی فقط یکی از این کلاس‌ها توضیح داده می‌شود، Grad-CAM ممکن است بیشتر روی بخش‌های مشترک مثل بدن تمرکز کند؛ در حالی که تفاوت اصلی در جزئیات ظریف‌تری مثل رنگ بال است. بنابراین مشکل اصلی این نیست که باید روش توضیح پیچیده‌تر شود، بلکه باید هدف توضیح عوض شود: به جای توضیح دادن خود کلاس هدف، باید تفاوت آن با یک کلاس مشابه توضیح داده شود. همین نگاه باعث می‌شود راه‌حل ساده‌تر شود، چون Finer-CAM صرفاً هدف توضیح را از logit کلاس هدف، به اختلاف logit کلاس هدف و کلاس مشابه تغییر می‌دهد و با همین مقایسه، ویژگی‌های مشترک کم‌رنگ و جزئیات تمایزدهنده برجسته می‌شوند.

(۲) استعاره‌ی بازی پیدا کردن تفاوت، شهودی درباره نحوه کار مغز انسان در تشخیص fine-grained ارائه می‌دهد. این شهود را زمانی درک می‌کنیم که برای تشخیص دو تصویر بسیار شبیه، دیگر به دنبال نکات کلی و اساسی در تصاویر نیستیم؛ بلکه به دنبال تفاوت‌ها و ظرایف کوچک می‌گردیم که دو تصویر را از هم متمایز می‌کنند. پس در طبقه‌بندی‌های fine-grained هم که کلاس‌ها خیلی شبیه به هم هستند، یک تفسیر خوب باید به جای نشان دادن کل نواحی مرتبط با کلاس هدف، تفاوت‌های کوچک آن با یک کلاس مشابه را پیدا کند. Finer-CAM دقیقاً همین کار را می‌کند. کلاس هدف را با یک کلاس مشابه مقایسه می‌کند تا ویژگی‌های مشترک کم‌رنگ شوند و جزئیات واقعاً متمایزکننده برجسته شوند.

Finer-CAM این شهود را به صورت ریاضی پیاده می‌کند. در Grad-CAM معمولی، وزن هر feature map با محاسبه گرادیان logit کلاس هدف (y^c) نسبت به آن feature map بدست می‌آید؛ در واقع فقط بررسی می‌شود که چه ویژگی‌هایی به کلاس هدف کمک می‌کنند. اما در Finer-CAM به جای توضیح دادن y^c ، اختلاف بین کلاس هدف و یک کلاس مشابه توضیح داده می‌شود. یعنی گرادیان عبارت $y^c - \gamma y^d$ نسبت به feature map محاسبه می‌گردد؛ که در این رابطه، y^d همان logit کلاس مشابه و γ شدت مقایسه است.

بنابراین وزن feature map ها به جای α_k^c ، به شکل $\alpha_k^{c,d} = \alpha_k^c - \gamma \alpha_k^d$ محاسبه می‌شود. یعنی اگر یک ویژگی هم برای کلاس هدف و هم برای کلاس مشابه مهم باشد، اثرش کم می‌شود؛ اما اگر بیشتر مخصوص کلاس هدف باشد، در نقشه نهایی برجسته‌تر می‌شود. به این ترتیب Finer-CAM به جای نمایش ویژگی‌های مشترک، جزئیات تمایزدهنده را نشان می‌دهد.


۳) ضریب γ در Finer-CAM ارزشمند است چون به کاربر اجازه می‌دهد که میزان مقایسه‌ی کلاس هدف با کلاس مشابه را تنظیم کند و در نتیجه بین دو نوع تفسیر تعادل برقرار کند. یکی تفسیر نمای کلی شیء و دیگری تفسیر دقیق‌تر از جزئیات ریز متمایزکننده. وقتی γ کوچک‌تر باشد، heatmap بیشتر روی نواحی کلی و اصلی شیء تمرکز می‌کند و Finer-CAM شبیه Grad-CAM می‌شود اما وقتی γ بزرگ‌تر شود، تفاوت کلاس هدف با کلاس مرجع بیشتر برجسته می‌شود و جزئیات ظریف‌تری که برای تشخیص fine-grained مهم‌اند نمایش داده می‌شوند. این قابلیت در حوزه‌هایی مثل زیست‌شناسی اهمیت زیادی دارد، چون تشخیص گونه‌های بسیار شبیه معمولاً به تفاوت صفات خاص و منحصر به فرد هر جفت گونه وابسته است. بنابراین Finer-CAM می‌تواند با مقایسه‌ی کلاس هدف با کلاس‌های مرجع مختلف، نواحی تمایزدهنده‌ی متفاوتی را پیدا کند و گونه‌ها را از هم تشخیص دهد.

۴) قابلیت activation faithfulness examination بررسی می‌کند که آیا نواحی فعال شده توسط مدل برای تشخیص تفاوت بین دو کلاس، با صفات واقعی و قابل نام‌گذاری آن کلاس‌ها هم‌خوانی دارند یا نه. در مقاله ادعا می‌شود که Finer-CAM می‌تواند هم در تنظیمات classifier معمولی و هم در مدل چندوجهی مثل CLIP به کار رود؛ در حالت چندوجهی، Finer-CAM با مقایسه‌ی دو prompt متنی، مثل «red epaulets» و «bird»، تلاش می‌کند ناحیه‌ای را پیدا کند که مفهوم خاص‌تر را از مفهوم کلی‌تر متمایز می‌کند؛ بنابراین به جای برجسته کردن کل پرنده، بخش مربوط به یک ویژگی خاص مانند لکه‌های قرمز را دقیق‌تر نشان می‌دهد. سپس اگر نواحی برجسته شده برای تفاوت بین کلاس‌ها با attribute‌های واقعی و قابل نام‌گذاری هم‌راستا باشند، می‌توان گفت که مدل تا حدی دانش درستی از تفاوت‌های صفات کلاس‌ها بدست آورده است؛ اما اگر اختلاف زیادی وجود داشته باشد، ممکن است مدل به عوامل نامربوط یا سوگیری‌ها تکیه کرده باشد. این موضوع برای اعتماد به مدل‌های هوش مصنوعی مهم است، چون نشان می‌دهد مدل فقط خروجی درست نمی‌دهد، بلکه تصمیمش تا حدی بر اساس نشانه‌های معنادار و قابل بررسی گرفته شده است.

زیربخش دوم: پیاده‌سازی

الف) مطابق با صورت پروژه از همان ۵ تصویر قسمت قبل استفاده شده است.

ب) کد این بخش در فایل q2.ipynb در فلدر Q2 موجود است و نتیجه به صورت زیر بدست آمده است:




شکل ۸: نمونه‌هایی از Saliency map های ایجاد شده توسط Grad-CAM و FinerGrad-CAM

بخش سوم: مقایسه

زیربخش اول: مقایسه دو روش

برای مقایسه دو روش می‌توانیم از عکس زیر استفاده کنیم:



شکل ۹: نمونه‌هایی از Saliency map های ایجاد شده توسط Grad-CAM و FinerGrad-CAM

تحلیل: با توجه به شکل‌های تولیدشده، تفاوت اصلی Grad-CAM و FinerGrad-CAM در نوع تمرکز آنها دیده می‌شود. Grad-CAM معمولاً نواحی کلی‌تر و وسیع‌تری از شیء را فعال می‌کند، چون فقط به دنبال بخش‌هایی است که امتیاز کلاس هدف را افزایش می‌دهند؛ برای مثال در تصاویر water tower، gazelle، و score board، ناحیه‌ی فعال‌شده بیشتر روی بدنه یا بخش اصلی شیء قرار گرفته است. اما FinerGrad-CAM علاوه بر کلاس هدف، کلاس‌های مرجع مشابه را هم وارد محاسبه می‌کند و بنابراین تلاش می‌کند نواحی‌ای را نشان دهد که کلاس هدف را از آن کلاس‌های مشابه جدا می‌کنند. با افزایش مقدار γ ، شدت جداسازی کلاس هدف از کلاس‌های مرجع بیشتر می‌شود و در بعضی نمونه‌ها، مثل academic gown و cauliflower، نقشه کمی متمرکزتر و حساس‌تر به بخش‌های خاص‌تر شیء می‌شود. با توجه به این موضوع می‌توانیم نتیجه بگیریم که این تصاویر، تصاویری هستند که کلاس هدف آنها با کلاس‌های مرجع شباهت

دارد و از این رو نتایج حاصل از دو روش تفاوت دارند. از طرفی دیگر در برخی تصاویر مثل gazelle تغییرات شدید نیست، که این موضوع می‌تواند به دلیل شباهت زیاد ویژگی‌های کلاس هدف و کلاس‌های مرجع یا نبودن جزئیات تمایزدهنده‌ی واضح در تصویر باشد. در مجموع، این نتایج نشان می‌دهد Grad-CAM برای فهمیدن ناحیه‌ی کلی مورد توجه مدل مناسب است، اما FinerGrad-CAM توجه بیشتری نسبت به جزئیات متمایزکننده نشان می‌دهد.

- [1] R. Agarwal, L. Melnick, N. Frosst, X. Zhang, B. Lengerich, R. Caruana, and G. E. Hinton. "Neural Additive Models: Interpretable Machine Learning with Neural Nets." 35th Conference on Neural Information Processing Systems (NeurIPS), 2021.
- [2] Z. Zhang, J. Gu, A. Chowdhury, Z. Mai, D. Carlyn, T. Berger-Wolf, Y. Su, and W.-L. Chao. "Finer-CAM: Spotting the Difference Reveals Finer Details for Visual Explanation." arXiv preprint arXiv:2501.11309, 2025.
- [3] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra. "Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization." Proceedings of the IEEE International Conference on Computer Vision (ICCV), 2017.
- [4] OpenAI ChatGPT, used only for conceptual discussion and consultation during report preparation. No generated text was copied.
- [5] Google Gemini, used only for conceptual discussion and consultation during report preparation. No generated text was copied.
- [6] Course slides: "14-Interpretable Machine Learning-2 ", "15-Interpretable ML-Saliency Map-CAM ".