



به نام خدا



دانشگاه تهران

دانشکده مهندسی برق و کامپیوتر

هوش مصنوعی قابل اعتماد

تمرین چهارم

نام و نام خانوادگی	سید محمد جواد شریفی
شماره دانشجویی	۸۱۰۱۰۲۴۶۹
تاریخ ارسال گزارش	۱۴۰۵/۰۵/۳

فهرست

4	سؤال اول: fairness
4	بخش اول: مبانی و نظریه
4	پرسش ۱: سه معیار مشاهده‌ای
7	پرسش ۲: استخراج یک نتیجه عدم امکان (اتحاد چولدچوا)
10	پرسش ۳: انصاف علی و خلاف واقع
12	بخش دوم: پرسش‌های مفهومی و کاربردی
12	پرسش ۴: مسئله جانشین / برچسب سلامت
13	پرسش ۵: انتخاب معیار، تحت قید عدم امکان (اعطای وام)
15	پرسش ۶: داوری مناقشه COMPAS (در پیوند با بخش اول)
17	پرسش ۷: فراتر از انصاف حاشیه‌ای: زیرگروه‌ها و زمان
19	بخش سوم: پیاده‌سازی و تحلیل تجربی
29	سوال دوم: حریم خصوصی در یادگیری ماشین و یادگیری فدرال
29	بخش اول: سؤالات توضیحی
29	زیربخش اول: حساسیت و مکانیزم لاپلاس
30	زیربخش دوم: انتشار خصوصی داده‌ها و Report Noisy Max
31	زیربخش سوم: تخصیص بودجه حریم خصوصی و ترکیب مکانیزم‌ها
34	بخش دوم: سؤالات مفهومی
34	زیربخش اول: حریم خصوصی، استحکام و یادگیری فدرال
35	زیربخش دوم: حملات حریم خصوصی و مسموم‌سازی در یادگیری فدرال
37	زیربخش سوم: مکانیزم‌های دفاعی و مبادله حریم خصوصی - استحکام - سودمندی
40	بخش سوم: سؤالات پیاده‌سازی
40	زیربخش اول: آماده‌سازی داده‌ها
42	زیربخش دوم: آموزش مدل فدرال

44.....	MEMBERSHIP INFERENCE	ارزیابی حملات
45.....	DIFFERENTIAL PRIVACY	دفاع مبتنی بر
51		مراجع

بخش اول: مبانی و نظریه

پرسش ۱: سه معیار مشاهده‌ای

الف) فرض می‌کنیم A متغیر ویژگی حساس (مانند جنسیت یا نژاد)، Y متغیر برچسب واقعی و $\hat{Y}$ بیانگر خروجی و پیش‌بینی مدل باشد:

۱. معیار استقلال (Independence): این معیار بیان می‌کند که پیش‌بینی مدل ($\hat{Y}$) باید به طور کامل از ویژگی حساس (A) مستقل باشد.

• رابطه صوری: $\hat{Y} \perp A$

• مفهوم احتمالاتی: $P(\hat{Y} = y | A = a) = P(\hat{Y} = y | A = b)$

۲. معیار جداسازی (Separation): این معیار بیان می‌کند که به شرط معلوم و ثابت بودن برچسب واقعی (Y)، پیش‌بینی مدل ($\hat{Y}$) باید از ویژگی حساس (A) مستقل باشد.

• رابطه صوری: $\hat{Y} \perp A | Y$

• مفهوم احتمالاتی: $P(\hat{Y} = y | Y = c, A = a) = P(\hat{Y} = y | Y = c, A = b)$

۳. معیار بسندگی (Sufficiency): این معیار نشان می‌دهد که به شرط ثابت بودن پیش‌بینی مدل ($\hat{Y}$)، برچسب واقعی (Y) کاملاً مستقل از ویژگی حساس (A) است. به بیان دیگر، خروجی مدل به تنهایی برای توصیف وضعیت کافی است.

• رابطه صوری: $Y \perp A | \hat{Y}$

• مفهوم احتمالاتی: $P(Y = y | \hat{Y} = \hat{y}, A = a) = P(Y = y | \hat{Y} = \hat{y}, A = b)$

ب) ۱. استقلال:

• نام استاندارد: برابری جمعیتی

• تساوی احتمال: در حالت باینری، احتمال مثبت و منفی شدن پیش‌بینی باید برای گروه‌های مختلف یکسان باشد.

$$P(\hat{Y} = 1 | A = 0) = P(\hat{Y} = 1 | A = 1)$$

۲. جداسازی:

- نام استاندارد: فرصت برابر یا برابری شانس‌ها
- تساوی احتمال: در استاندارد فرصت برابر و برابری شانس‌ها، احتمال مثبت شدن پیش‌بینی به شرط آنکه برچسب واقعی مثبت باشد، باید برای هر دو گروه برابر باشد (برابری True Positive Rate).

$$P(\hat{Y} = 1 | Y = 1, A = 0) = P(\hat{Y} = 1 | Y = 1, A = 1)$$

۳. بسندگی:

- نام استاندارد: برابری پیش‌بینی یا برابری کالیبراسیون
- تساوی احتمال: در برابری پیش‌بینی، به شرطی که مدل خروجی مثبت داده باشد، احتمال مثبت بودن برچسب واقعی باید برای گروه‌های مختلف یکسان باشد.

$$P(Y = 1 | \hat{Y} = 1, A = 0) = P(Y = 1 | \hat{Y} = 1, A = 1)$$

برابری کالیبراسیون هم دقیقاً معادل همین گزاره خواهد بود.

ج) ۱. معیار استقلال

شهود هنجاری: این معیار جلوی تبعیض را می‌گیرد. در واقع می‌خواهد نگذارد که یک گروه خاص، به دلیل برخی الگوهای ناعادلانه (که غالباً ریشه فرهنگی و تاریخی دارند)، از دریافت یک فرصت محروم بمانند.

کاربرد و توجیه: کاربرد آن در سیستم‌های اعطای وام در مناطقی است که قبلاً درگیر تبعیض بوده‌اند. در اینجا استقلال بهترین معیار است، زیرا اگر به داده‌های گذشته نگاه کنیم، یک اقلیت خاص به خاطر فقر، وام کمتری گرفته است و مدل unfair همان روند را یاد گرفته است و این موضوع را تشدید کرده است. اما این معیار بانک را مجبور می‌کند بدون توجه به این پیشینه، سهم عادلانه‌ای از وام‌ها را به آن اقلیت بدهد و این چرخه اشتباه و ناعادلانه را بشکند.

۲. معیار جداسازی

شهود هنجاری: این معیار می‌خواهد نگذارد که اگر دو نفر در دنیای واقعی، واقعا شایستگی یک چیزی را دارند، یکی از آن‌ها فقط به خاطر عضویت در یک گروه خاص، به اشتباه رد شود. یعنی افراد مستعد در همه گروه‌ها باید شانس مساوی برای تایید شدن داشته باشند.

کاربرد و توجیه: کاربرد آن در سیستم‌های غربالگری رزومه برای استخدام است. در اینجا جداسازی بهترین انتخاب است. چون برای شرکت مهم است که افراد توانمند را از دست ندهد. اگر یک فرد از یک گروه اقلیت

و یک فرد از گروه اکثریت هر دو واقعا تخصص لازم را داشته باشند، این معیار تضمین می‌کند که الگوریتم، فرد اقلیت را با احتمال بیشتری به اشتباه رد نمی‌کند و هر دو با شانس برابر پذیرفته می‌شوند.

۳. معیار بسندگی

شهود هنجاری: این معیار به این هدف است که اگر مدل به کسی امتیاز مشخصی داد، این امتیاز باید در همه گروه‌ها دقیقا به معنای همان درصد از شایستگی یا خطر واقعی باشد (استاندارد دو گروه یکسان باشد). در واقع این معیار جلوی گمراه‌کننده بودن خروجی مدل برای بعضی گروه‌های خاص را می‌گیرد.

کاربرد و توجیه: کاربرد آن در سیستم‌های ارزیابی ریسک پزشکی در بیمارستان‌ها است. در اینجا بسندگی بهترین معیار است چون پزشک در شرایط بحرانی وقت ندارد ببیند بیمار متعلق به کدام گروه است تا نمره مدل را دوباره تفسیر کند. پزشک باید مطمئن باشد که وقتی مدل می‌گوید امتیاز خطر یک بیمار بالا است، این امتیاز چه برای یک بیمار پیر و چه جوان و چه زن و چه مرد، دقیقا به یک اندازه نشان‌دهنده خطر واقعی است.

د) زمانی که دو گروه دارای نرخ پایه متفاوتی از نظر برچسب واقعی باشند، اگر بخواهیم معیار استقلال را برقرار کنیم، مدل مجبور است نرخ پیش‌بینی‌های مثبت را برای هر دو گروه یکسان کند. این کار مستلزم آن است که مدل برای گروهی که نرخ پایه کمتری دارد، استاندارد و آستانه تصمیم‌گیری را پایین بیاورد. به دلیل این تفاوت در استانداردها، خروجی مدل در هر دو گروه، دیگر ارزش و معنای یکسانی نخواهد داشت و در نتیجه معیار بسندگی نقض می‌شود.

اگر بخواهیم این مطلب را با استدلال ریاضی و صوری بیان کنیم، می‌توانیم از برهان خلف استفاده کنیم. یعنی فرض کنیم که دو معیار استقلال و بسندگی همزمان برقرار باشند و در انتها به این نتیجه برسیم که نرخ‌های پایه با هم برابر هستند که این موضوع خلاف فرض سوال است.

فرض می‌کنیم هر دو معیار همزمان برقرار هستند. طبق قانون احتمال کل داریم:

$$P(Y = 1|A = a) = \sum_{y \in \{0,1\}} P(Y = 1|\hat{Y} = y, A = a) \cdot P(\hat{Y} = y|A = a)$$

حال طبق فرض برقراری بسندگی داریم:

$$P(Y = 1|\hat{Y} = y, A = a) = P(Y = 1|\hat{Y} = y)$$

حال طبق فرض برقراری استقلال داریم:

$$P(\hat{Y} = y|A = a) = P(\hat{Y} = y)$$

با جایگذاری روابط دوم و سوم در رابطه اول به رابطه زیر می‌رسیم:

$$P(Y = 1|A = a) = \sum_{y \in \{0,1\}} P(Y = 1|\hat{Y} = y) \cdot P(\hat{Y} = y) = P(Y = 1)$$

با عددگذاری a در رابطه بالا به نتیجه زیر می‌رسیم:

$$P(Y = 1|A = 0) = P(Y = 1|A = 1) = P(Y = 1)$$

بنابراین به این نتیجه رسیدیم که نرخ‌های پایه با هم برابر هستند که این صراحتاً خلاف فرض سوال است و بنابراین فرض خلف نادرست بوده و این دو معیار با هم ناسازگار هستند.

پرسش ۲: استخراج یک نتیجه عدم امکان (اتحاد چولدچوا)

الف) از تعریف PPV شروع می‌کنیم:

$$PPV = \frac{TP}{TP + FP}$$

طرفین و وسطین می‌کنیم و سپس مرتب‌سازی می‌کنیم:

$$PPV \cdot TP + PPV \cdot FP = TP$$

$$PPV \cdot FP = TP - (PPV \cdot TP)$$

$$PPV \cdot FP = TP \cdot (1 - PPV)$$

دو طرف را بر PPV تقسیم می‌کنیم:

$$FP = TP \cdot \frac{1 - PPV}{PPV}$$

حالا باید TP و FP را محاسبه کنیم و در معادله فوق جایگذاری کنیم.

محاسبه TP: تعداد مثبت‌های درست برابر است با تعداد کل مثبت‌ها ضربدر TPR. اگر اندازه کل جامعه را n در نظر بگیریم که نرخ پایه آن p است، تعداد کل مثبت‌ها برابر np است. مقدار TPR هم برابر است با $1 - FNR$. پس:

$$TP = n \cdot p \cdot (1 - FNR)$$

محاسبه FP: تعداد مثبت‌های کاذب برابر است با تعداد کل منفی‌ها ضربدر FPR. اگر اندازه کل جامعه را n در نظر بگیریم که نرخ پایه آن p است، تعداد کل منفی‌ها برابر $n(1 - p)$ است. پس:

$$FP = n \cdot (1 - p) \cdot FPR$$

حالا FP و TP بدست آمده را در معادله بالا جایگذاری می‌کنیم:

$$n \cdot (1 - p) \cdot FPR = [n \cdot p \cdot (1 - FNR)] \cdot \frac{1 - PPV}{PPV}$$

$$(1 - p) \cdot FPR = p \cdot (1 - FNR) \cdot \frac{1 - PPV}{PPV}$$

حالا دو طرف را بر $1 - p$ تقسیم می‌کنیم:

$$FPR = \frac{p}{1 - p} \cdot \frac{1 - PPV}{PPV} \cdot (1 - FNR)$$

ب) برای اثبات از برهان خلف استفاده می‌کنیم. یعنی فرض می‌کنیم که FPR و FNR در هر دو گروه با هم برابر است.

با توجه به فرض خلف و با توجه به اینکه در صورت سوال گفته شده که هر دو گروه PPV یکسان دارند، پس تساوی‌های زیر برقرار است:

$$FNR_0 = FNR_1 = FNR$$

$$FPR_0 = FPR_1 = FPR$$

$$PPV_0 = PPV_1 = PPV$$

حال از اتحاد قسمت الف استفاده می‌کنیم و مقادیر ثابت را در معادله هر دو گروه جایگذاری می‌کنیم. در این صورت تمامی ترم‌ها با هم برابر می‌شوند (با فرض تباهیده یا مرزی نبودن مدل) و به تساوی زیر می‌رسیم:

$$\frac{p_0}{1 - p_0} = \frac{p_1}{1 - p_1}$$

این تساوی تنها در شرایط $p_0 = p_1$ برقرار است که خلاف فرض سوال است و بنابراین فرض خلف رد می‌شود و نتیجه می‌گیریم که FPR و FNR همزمان نمی‌تواند در دو گروه برابر باشد.

این استدلال زمانی درست است که مدل در حالت تباهیده یا مرزی نباشد. منظور از این حالت، شرایطی است که متغیرهای ارزیابی روی مرزهای احتمالات (صفر یا یک) قرار می‌گیرند و دو طرف اتحاد چولدچوا را به فرم بدیهی $0 = 0$ تبدیل می‌کنند. در این صورت تساوی فوق را نمی‌توانیم نتیجه بگیریم.

- حالت تباهیده: مدل خاصیت یادگیری و تفکیک خود را از دست داده است. مثلاً مدل همه ورودی‌ها را منفی دسته‌بندی می‌کند، در نتیجه نرخ خطای منفی کاذب ۱۰۰ درصد می‌شود ($FNR = 1$) و عبارت سمت راست صفر می‌گردد.

• حالت مرزی: مدل مطلقاً هیچ خطایی ندارد. مثلاً دقت پیش‌بینی مثبت کامل است ($PPV = 1$) و کسر مربوطه صفر می‌شود. از آنجا که در سیستم‌های واقعی و خطادار دستیابی به خطای صفر محال است، این حالت صرفاً روی کاغذ و ممکن است و باید در استدلال ریاضی لحاظ شود.

(ج) این شرکت بر روی معیار بسندگی (برابری پیش‌بینی یا کالیراسیون) تمرکز کرد. آن‌ها نشان دادند که مدل دارای ارزش اخباری مثبت (PPV) یکسانی برای هر دو گروه نژادی است؛ به این معنا که یک امتیاز ریسک مشخص، احتمال تکرار جرم یکسانی را برای هر دو نژاد سفیدپوست و سیاه‌پوست نشان می‌دهد.

خبرنگاران نقض معیار جداسازی (به‌طور خاص، نابرابری در نرخ مثبت کاذب یا FPR) را برجسته کردند. آن‌ها اثبات کردند که متهمان سیاه‌پوستی که در واقعیت مجدداً جرمی مرتکب نشده بودند، با احتمال بسیار بیشتری نسبت به سفیدپوستان مشابه، به اشتباه به عنوان «پرخطر» دسته‌بندی شده‌اند.

با توجه به نتیجه قسمت قبل، این موضوع اجتناب‌ناپذیر بود؛ زیرا در مجموعه داده‌های موجود، نرخ پایه تکرار جرم (p) برای گروه سیاه‌پوستان به طور معناداری بالاتر از گروه سفیدپوستان بود. با توجه به اتحاد چولدچوا که در بخش (ب) ثابت شد، زمانی که نرخ پایه دو گروه نامساوی باشد و مدل، معیار PPV برابر را ارضا کند، از نظر ریاضی محال است که نرخ خطاهای FPR و FNR به صورت هم‌زمان در دو گروه برابر شود.

(د) جمع‌آوری داده‌های بیشتر یا باکیفیت‌تر نمی‌تواند این سه معیار را به طور هم‌زمان برقرار کند. بر اساس اتحاد چولدچوا، برقراری هم‌زمان واسنجی (PPV)، برابری FPR و برابری FNR تنها در دو حالت محدود امکان‌پذیر است. حالت اول برابری نرخ‌های پایه است. یعنی اینکه واقعیت پنهان جامعه در هر دو گروه دقیقاً یکسان باشد ($p_0 = p_1$). حالت دوم هم این است که مدل پیش‌بینی‌کننده هیچ خطایی نداشته باشد (دقت ۱۰۰ درصد) یا کاملاً از کار افتاده باشد.

بنابراین، این بده‌بستان میان معیارهای انصاف، یک محدودیت بنیادی و ساختاری است، نه صرفاً یک مصنوع ناشی از نمونه متناهی یا نویز در داده‌ها. تضاد میان این معیارها ریشه در قوانین جبری احتمالات و تفاوت‌های واقعی در نرخ‌های پایه دارد؛ بنابراین هیچ حجم عظیمی از داده‌های جدید نمی‌تواند تغییری در این اصل ایجاد کند.

پرسش ۳: انصاف علی و خلاف واقع

الف) بر اساس چارچوب مدل علی ساختاری (SCM)، یک مدل طبقه‌بند ($\hat{Y}$) نسبت به ویژگی حساس (A) دارای انصاف خلاف واقع است، اگر برای یک فرد مشخص، خروجی مدل در دنیای واقعی با خروجی مدل در یک دنیای فرضی (که در آن مقدار A تغییر کرده است) توزیع یکسانی داشته باشد.

این موضوع را می‌توانیم به زبان ریاضی و با استفاده از عملگر do تعریف کنیم:

$$P(\hat{Y} = y \mid do(A = a), U = u) = P(\hat{Y} = y \mid do(A = a'), U = u)$$

در اینجا U ویژگی‌های پنهان پس‌زمینه هستند که مربوط به هویت و ذات یک نمونه هستند. این ویژگی‌ها تحت تأثیر متغیر A قرار نمی‌گیرند و با تغییر A ، تغییر نمی‌کنند.

همانطور که مشخص است، ما روی ویژگی حساس A مداخله می‌کنیم و مقدار آن را به شکل فرضی تغییر می‌دهیم تا اثر خالص آن را بررسی کنیم.

همچنین ویژگی‌های پس‌زمینه U ثابت نگه داشته می‌شوند. این ویژگی‌ها تحت تأثیر A نیستند و بنابراین، برای آنکه بتوانیم تأثیر خالص A را حساب کنیم، باید آنها را ثابت فرض کنیم.

ب) در گراف علی داده شده، متغیر A از دو مسیر بر روی خروجی $\hat{Y}$ تأثیر می‌گذارد.

مسیر مستقیم ($A \rightarrow \hat{Y}$): این مسیر نشان‌دهنده تأثیر مستقیم متغیر حساس بر روی تصمیم‌گیری است و به عنوان مسیر پراکسی (Proxy) یا تبعیض‌آمیز شناخته می‌شود.

مسیر غیرمستقیم ($A \rightarrow X \rightarrow \hat{Y}$): این مسیر نشان می‌دهد که متغیر حساس از طریق یک ویژگی واسطه (سال‌های تجربه) روی خروجی تأثیر می‌گذارد و به عنوان مسیر تبیین‌کننده (Resolving) در نظر گرفته می‌شود.

یک مدل منصف باید به طور کامل جلوی اثرات مسیر پراکسی، یعنی تأثیر مستقیم A بر $\hat{Y}$ را بگیرد تا تصمیم‌گیری صرفاً بر اساس ویژگی حساس انجام نشود. اما اثر مسیر تبیین‌کننده (از طریق X) ممکن است مشروع باشد، زیرا سابقه کار می‌تواند یک معیار منطقی برای استخدام باشد.

تشخیص اینکه مسیر تبیین‌کننده کاملاً مشروع است یا خود ابزاری برای بازتولید تبعیض است، از روی داده‌های خام قابل استخراج نیست. برای مثال، اگر در یک جامعه زنان به دلیل قوانین ناعادلانه گذشته شانس کمتری برای کسب سابقه کار داشته‌اند، استفاده از متغیر X به عنوان معیار استخدام نامشروع است. اما اگر فرصت‌ها برابر بوده باشد، مشروع است. بنابراین، تعیین مشروعیت این مسیر نیازمند درک

ساختارهای اجتماعی، فرهنگی و تاریخی و همچنین قوانین حقوقی است که طبیعتاً به تنهایی از داده‌ها قابل استخراج نیست.

ج) داده‌های خام روابط همبستگی میان متغیرها را نشان می‌دهند و ساختار علی را مشخص نمی‌کنند. به همین دلیل، دو تحلیل‌گر می‌توانند برای یک مجموعه داده یکسان، بر اساس پیش‌فرض‌های اجتماعی یا دانش تخصصی خود، دو گراف علی متفاوت رسم کنند. از آنجا که تمام محاسبات مربوط به متغیرهای پنهان و شبیه‌سازی‌های دنیای موازی مستقیماً روی این گراف‌ها انجام می‌شود، تفاوت در ساختار گراف باعث می‌شود خروجی محاسبات خلاف واقع برای یک فرد مشخص در دو ساختار متفاوت باشد و در نتیجه دو تحلیل‌گر به نتایج کاملاً متضادی درباره منصف بودن سیستم برسند.

این پدیده ثابت می‌کند که انصاف علی یک معیار کاملاً عینی نیست. در واقع، این نوع از انصاف به شدت ذهنی و وابسته به قضاوت‌های انسانی، فرضیات تحلیل‌گر و نحوه مدل‌سازی او از جامعه است و نمی‌توان آن را یک حقیقت محض ریاضی دانست.

بر اساس استدلال‌های فوق، ادعای دانشجو مبنی بر عینی بودن انصاف خلاف واقع نادرست است. ساختار علی مستقیماً از دل داده‌ها بیرون نمی‌آید، بلکه این انسان است که مدل علی را بر داده‌ها تحمیل می‌کند؛ بنابراین نتیجه‌ای که بدست می‌آید نیز یک نتیجه عینی نیست.

بخش دوم: پرسش‌های مفهومی و کاربردی

پرسش ۴: مسئله جانشین / برچسب سلامت

الف) به نظر من در این سناریو ۲ سوگیری اصلی وجود دارد:

۱- سوگیری برچسب: زیرا متغیر هدف یعنی هزینه درمان، جانشین نامناسبی برای نیاز واقعی به درمان است.

۲- سوگیری تاریخی: زیرا به جهت آنکه گروه‌های حاشیه‌نشین و کم درآمد هزینه کمتری بابت درمان پرداخت می‌کنند، یعنی از قبل در داده‌ها یک بی‌عدالتی وجود داشته است و در نتیجه داده‌های مربوط به هزینه هم این بی‌عدالتی را در نتایج بازتاب می‌دهند.

آسیب از جایی وارد می‌شود که با انتخاب هزینه به عنوان جانشین سلامت، توسعه‌دهنده به طور ناخواسته نابرابری‌های اقتصادی و اجتماعی را به عنوان یک الگو به مدل آموزش می‌دهد. از آنجا که در یک سطح بیماری کاملاً برابر، هزینه صرف شده برای گروه‌های به حاشیه رانده شده کمتر از گروه اکثریت است، مدل این تفاوت مالی را به حساب تفاوت در سلامت می‌گذارد. در نتیجه، این انتخاب باعث می‌شود سهمیه مراقبت‌های ویژه برای این گروه به شدت کاهش یابد و عدالت مدل زیر سوال برود.

ب) خیر. رویکرد انصاف از طریق ناآگاهی جلوی بروز این ناعدالتی را نمی‌گرفت. برای این ادعا دو دلیل به ذهنم می‌رسد:

۱- زیرا مشکل اصلی در متغیر هدف است. در این سناریو، ریشه اصلی ناعدالتی در انتخاب متغیر هدف (یعنی هزینه به جای نیاز پزشکی) نهفته است. حتی اگر مدل متغیر حساس (مثلاً طبقه اجتماعی) را نبیند، باز هم در حال یادگیری تابعی است که خروجی آن به دلیل نابرابری‌های ساختاری در سیستم، ذاتاً سوگیری دارد و بنابراین باز هم مدل عدالت ندارد.

۲- در مجموعه داده‌های واقعی، ویژگی‌های متعددی مانند کد پستی محل سکونت، وضعیت درآمد، نوع بیمه درمانی و سوابق مراجعه به بیمارستان وجود دارند که همبستگی بسیار بالایی با ویژگی حساس (مثلاً طبقه اجتماعی) دارند. مدل‌های یادگیری ماشین به راحتی می‌توانند ویژگی حساس حذف شده را از طریق ترکیب این متغیرهای غیرمستقیم استنتاج و بازسازی کنند. در نتیجه، مدل دقیقاً همان الگوهای تبعیض‌آمیز را یاد گرفته و بازتولید می‌کند.

ج) معیار مشاهده‌ای جداسازی (Separation) می‌توانست این مسئله را آشکار کند. صورت سوال صراحتاً بیان می‌کند که در سطح بیماری برابر، بیماران گروه حاشیه‌ای کمتر ثبت‌نام می‌شوند. این یعنی اگر برچسب

واقعی سلامت (Y) را ثابت در نظر بگیریم، احتمال دریافت پیش‌بینی مثبت ($\hat{Y} = 1$) برای گروه حاشیه‌ای به شدت پایین‌تر است که این یعنی احتمال $P(\hat{Y} = 1 | Y = 1, A)$ در گروه‌ها برابر نیست و نقض مستقیم معیار جداسازی نسبت به متغیر هدف (سلامت واقعی) است.

اگر ممیزی بر اساس متغیر جانشین (هزینه) انجام می‌شد، این ناعدالتی پنهان می‌ماند. دلیل این امر آن است که مدل برای پیش‌بینی هزینه train شده بود. بنابراین، اگر ممیز بیماران را بر اساس «هزینه برابر» جدا می‌کرد، می‌دید که مدل به هر دو گروه با احتمال نسبتاً یکسانی اجازه ثبت‌نام می‌دهد (نسبت فرصت به هزینه در گروه‌ها مساوی بود). ممیز فریب این برابری را می‌خورد، زیرا متوجه نمی‌شد که خود متغیر هزینه از پایه دچار سوگیری است و افراد با هزینه برابر در واقعیت دارای سطح بیماری متفاوتی هستند.

د) راه حل من «تغییر متغیر هدف از معیارهای مالی به شاخص‌های پزشکی» است. به جای استفاده از هزینه درمانی آینده به عنوان متغیر هدف، مدل باید برای پیش‌بینی از شاخص‌های واقعی و مستقیم سلامت، مانند تعداد بیماری‌های مزمن فعال، نتایج آزمایشگاهی (مانند قند یا فشار خون)، یا ترکیبی از شاخص‌های سلامت آموزش دیده شود.

محدودیت‌های این راه حل: جمع‌آوری، تجمیع و استانداردسازی داده‌های بالینی بسیار دشوارتر و پرهزینه‌تر از داده‌های صورت‌حساب مالی است. پرونده‌های سلامت اغلب ناقص هستند، ساختار یکپارچه‌ای ندارند و استخراج اطلاعات از آنها مشکل است.

ریسک انصاف جدید: این تغییر می‌تواند منجر به بروز سوگیری‌های جدیدی مثل سوگیری اندازه‌گیری و بازنمایی شود. گروه‌های حاشیه‌نشین به دلیل دسترسی کمتر به امکانات بهداشتی، ممکن است کمتر مورد آزمایش‌های تشخیصی و چکاپ‌های دوره‌ای قرار گیرند. در نتیجه، فقدان داده‌های پزشکی برای این گروه، ممکن است توسط الگوریتم به اشتباه به عنوان عدم وجود بیماری (سلامت کامل) تفسیر شود و مجدداً این بیماران را از دریافت سهمیه مراقبت‌های ویژه محروم سازد.

پرسش ۵: انتخاب معیار، تحت قید عدم امکان (اعطای وام)

الف) در این سناریو، مهم‌ترین آسیب تخصیصی، محروم شدن ناعدالانه افراد (به ویژه در گروه‌های اقلیت) از دسترسی به منابع مالی و اعتباری است که می‌تواند منجر به کاهش فرصت‌های اقتصادی و افت کیفیت زندگی آن‌ها شود.

عدم تقارن خطای مثبت کاذب و منفی کاذب برای ذی‌نفعان:

در این مسئله، پیش‌بینی مثبت معادل تایید وام است. بنابراین مثبت کاذب، یعنی وام دادن به فردی که بازپرداخت نمی‌کند و منفی کاذب یعنی رد کردن فردی که توان بازپرداخت داشته است.

۱. متقاضیان: متقاضی بیشترین آسیب را از خطای منفی کاذب می‌بیند. طبق صورت مسئله، بزرگترین نگرانی متقاضی از دست دادن وامی است که شایستگی دریافت آن را داشته است. بنابراین هزینه خطای منفی کاذب مستقیماً توسط متقاضی و به شکل از دست دادن فرصت و سرمایه پرداخت می‌شود. مثبت کاذب در لحظه دریافت وام برای متقاضی هزینه مستقیمی ندارد.

۲. بانک: برای بانک که هدفش بیشینه کردن سود است، عدم تقارن شدیدی به سمت خطای مثبت کاذب وجود دارد. هزینه خطای منفی کاذب صرفاً عدم النفع (از دست رفتن سود بهره یک وام) است؛ اما خطای مثبت کاذب به معنای از دست رفتن کل اصل سرمایه و ضرر هنگفت مالی است. پس بانک بیشترین آسیب را از خطای مثبت کاذب می‌بیند.

۳. نهادهای ناظر: برای نهادهای ناظر، عدم تقارن به سمت خطای منفی کاذب (رد کردن متقاضی شایسته) وجود دارد. مخصوصاً زمانی که این خطا به صورت نامتناسب و سیستماتیک روی یک گروه خاص (مانند اقلیت‌ها) متمرکز شود. از دید ناظر، اگر سیستم یک متقاضی بدحساب را تایید کند (خطای مثبت کاذب)، این صرفاً یک اشتباه تجاری برای خود بانک است؛ اما اگر سیستم متقاضیان شایسته اقلیت را رد کند (خطای منفی کاذب)، این یک تبعیض ساختاری و نقض حقوق مدنی (مانند قاعده هشتاد درصد) است که جرمه‌ای را برای بانک به همراه دارد.

ب) در این سناریو، معیار برابری جمعیتی (استقلال) به عنوان معیار اصلی انتخاب می‌شود.

با اجرای برابری جمعیتی، بانک نرخ تایید وام را برای گروه‌های مختلف یکسان می‌کند. این انتخاب پاسخ مستقیمی به دغدغه نهادهای ناظر است که روی قاعده هشتاد درصد و تاثیر نامتناسب تمرکز دارند. همچنین، این معیار دغدغه متقاضیان اقلیت را که بیشترین آسیب را از خطای منفی کاذب (رد شدن ناعادلانه) می‌بینند، برطرف می‌کند. تخصیص وام بیشتر به این گروه‌ها اثرات محرومیت تاریخی را کاهش داده و در بلندمدت مشتریان وفاداری برای بانک جذب می‌کند.

با توجه به اتحاد چولدچوا در پرسش ۲، معیارهای واسنجی و برابری شانس‌ها تا حدی از دست می‌روند. چرا که با این تصمیم، برخی موارد قربانی می‌شوند. قربانی اول، سودآوری بانک است. برای برابر کردن نرخ تایید، بانک باید وام‌های بیشتری به افراد با ریسک بالای عدم بازپرداخت در گروه اقلیت بدهد. این کار خطای مثبت کاذب را افزایش داده و زیان مالی مستقیمی به سیستم تحمیل می‌کند.

قربانی دوم، متقاضیان شایسته در گروه اکثریت هستند. بانک برای حفظ تعادل آماری و رعایت حد مجاز نهادهای ناظر، مجبور می‌شود افراد توانمند این گروه را که کاملاً توانایی بازگرداندن پول را دارند رد کند (افزایش عمدی خطای منفی کاذب). در واقع، شایستگی فردی فدای توازن گروهی می‌شود.

پرسش ۶: داوری مناقشه COMPAS (در پیوند با بخش اول)

الف) ادعای تجربی ProPublica: ادعای اصلی روزنامه‌نگاران این بود که الگوریتم دسته‌بندی دارای سوگیری نژادی است. زیرا خطاهای آن به شکل نامتقارنی روی گروه‌های نژادی توزیع شده است. به طور خاص، آن‌ها نشان دادند که نرخ مثبت کاذب (FPR) برای متهمان سیاه‌پوست به مراتب بالاتر از متهمان سفیدپوست است؛ یعنی سیستم متهمان سیاه‌پوستی را که در آینده جرمی مرتکب نمی‌شدند، بسیار بیشتر از متهمان سفیدپوست به عنوان پرخطر دسته‌بندی می‌کرد که نشان‌دهنده نقض معیار برابری شانس‌ها است.

پاسخ اصلی Northpointe: شرکت سازنده در پاسخ ادعا کرد که سیستم کاملاً منصفانه است زیرا نمرات ریسک خروجی مدل برای تمامی گروه‌های نژادی به طور یکسان واسنجی (کالیبره) شده است. استدلال آن‌ها این بود که ارزش اخباری مثبت (PPV) برای هر دو گروه برابر است؛ به این معنا که یک نمره ریسک مشخص، فارغ از نژاد متهم، ارزش پیش‌بینی‌کننده یکسانی برای تکرار جرم در دنیای واقعی دارد و سیستم معیار بسندگی را کاملاً برآورده می‌کند.

ب) شرکت سازنده حق داشت، زیرا آن‌ها سیستم را طوری طراحی کرده بودند که ارزش اخباری مثبت (PPV) برای هر دو گروه کاملاً برابر باشد. این یعنی مدل آن‌ها کالیبره بود و پیش‌بینی خطر برای هر دو گروه معنای یکسانی داشت.

روزنامه‌نگاران هم حق داشتند، زیرا آن‌ها خروجی‌ها را بررسی کردند و دیدند که نرخ مثبت کاذب (FPR) برای سیاه‌پوستان بسیار بیشتر از گروه سفیدپوستان است و مدل در این موضوع عدالت ندارد. علت اینکه هر دو طرف همزمان حق دارند ریشه در اتحاد پرسش ۲ (اتحاد چولدچوا) دارد:

$$FPR = \frac{p}{1-p} \cdot \frac{1-PPV}{PPV} \cdot (1-FNR)$$

در داده‌های واقعی، نرخ پایه تکرار جرم (p) در گروه سیاه‌پوستان به طور معناداری بیشتر از گروه سفیدپوستان بود. پس کسر اول در سمت راست معادله برای گروه سیاه‌پوستان مقدار بزرگتری خواهد داشت. از آنجا که شرکت سازنده مقدار PPV را برای هر دو گروه ثابت نگه داشته بود، طبق این اتحاد، از نظر ریاضی غیرممکن است که بتوان به طور همزمان مقادیر خطای FPR و FNR را هم برابر کرد. به دلیل

بزرگتر بودن ضریب نرخ پایه در گروه سیاه‌پوستان، برای برقراری تساوی، یا باید FNR گروه سیاه‌پوستان بالاتر باشد و یا FPR آنها. بالاتر بودن FNR به معنای آن است که سیستم به صورت خودخواسته، تعدادی از متهمان پرخطر سیاه‌پوست را کم خطر جلوه دهد که این موضوع کاملاً خطرناک و پرریسک است. بنابراین سیستم ترجیح می‌دهد FPR بالاتری را به این گروه تحمیل می‌کند تا تساوی برقرار بماند.

بنابراین هر دو طرف کاملاً درست می‌گفتند، زیرا به دو معیار انصاف متفاوت اشاره می‌کردند که هر دو موضوعیت دارند ولی با هم $trade\ off$ دارند و ممکن نیست که در این مسئله، هر دو به طور کامل رعایت شوند.

ج) به نظر من در این موضوع، معیار جداسازی و با تأکید بر برابری نرخ مثبت کاذب باید در اولویت باشد. در این سیستم، مثبت کاذب (FP) به معنای طبقه‌بندی پرخطر برای متهمی است که در واقعیت هیچ جرم مجددی مرتکب نخواهد شد. هزینه این خطا تماماً و مستقیماً بر خود فرد تحمیل می‌شود. این هزینه شامل سلب آزادی، حبس ناعادلانه، از دست دادن شغل، فروپاشی خانواده و آسیب‌های شدید روانی است. منفی کاذب (FN) به معنای طبقه‌بندی کم‌خطر برای متهمی است که در آینده دوباره جرم می‌کند. هزینه این خطا به شکل کاهش امنیت عمومی، بر دوش جامعه و قربانیان احتمالی آینده می‌افتد.

با توجه به نکات فوق، ارزیابی من این است که هزینه اخلاقی FP سنگین‌تر از هزینه اخلاقی FN است و معتقد هستم که در موضوع عدالت کیفری ما باید معیار جداسازی را با تأکید بر برابری FPR در اولویت قرار دهیم. چرا که اگر مانند شرکت Northpointe معیار واسنجی را انتخاب کنیم و اجازه دهیم خطای مثبت کاذب برای گروه اقلیت بیشتر باشد، در واقع داریم هزینه تامین امنیت جامعه (کاهش جرم مجدد) را مستقیماً از سلب آزادی گروه اقلیت بی‌گناه می‌پردازیم که روشی بسیار غیراخلاقی است. من معتقدم که ما به هیچ عنوان حق نداریم که یک انسان بی‌گناه را مجازات کنیم حتی اگر این کار ما باعث شود که چند نفر گناهکار هم آزاد شوند.

د) من هم با این گزاره موافقم که چنین سامانه‌ای نباید در سیستم عدالت کیفری مستقر شود. وقتی اثبات می‌شود که برآورده کردن هم‌زمان معیارهای انصاف به دلیل تفاوت در نرخ‌های پایه از نظر ریاضی غیرممکن است، استقرار سیستم به معنای پذیرش آگاهانه بی‌عدالتی علیه یک گروه جمعیتی خاص است.

علاوه بر معیارهای انصاف، موارد دیگری هم وجود دارند که باعث بروز مشکلاتی می‌شوند که نتیجه آن استفاده نکردن از این سامانه است. از جمله این موارد می‌توان به حلقه بازخورد اشاره کرد.

اگر سیستم بر اساس داده‌های تاریخی یک گروه را پرخطر ارزیابی کند، نیروهای پلیس نظارت خود را بر آن گروه را افزایش می‌دهند. این نظارت بیشتر منجر به کشف جرائم خردتر و دستگیری‌های بیشتر می‌شود که این داده‌های جدید، مجدداً وارد سیستم شده و ارزیابی پرخطر بودن آن گروه را تایید می‌کند. این یک چرخه باطل است که ربطی به ذات مجرمانه افراد ندارد و صرفاً نتیجه نظارت نامتقارن است.

پرسش ۷: فراتر از انصاف حاشیه‌ای: زیرگروه‌ها و زمان

الف) برای نشان دادن این موضوع مثال زیر را مطرح می‌کنیم:

یک کمپانی برای جذب نیروهای جدید یک آگهی داده است. ۱۰۰ نفر برای این آگاهی درخواست داده‌اند و کمپانی قصد دارد که ۵۰ نفر را جذب کند.

این ۱۰۰ نفر متقاضی به این صورت هستند که ۲۵ نفر مرد سیاه‌پوست، ۲۵ نفر مرد سفیدپوست، ۲۵ نفر زن سیاه‌پوست و ۲۵ نفر زن سفیدپوست هستند.

حالا اگر مدل ما، همه ۲۵ مرد سفیدپوست و همه ۲۵ زن سیاه‌پوست را انتخاب کند و از مردان سیاه‌پوست و زنان سفیدپوست هیچ انتخابی نکند، معیار انصاف روی هر ویژگی حساس (نژاد و جنسیت) رعایت شده است (چون دقیقاً ۲۵ مرد و ۲۵ زن استخدام شده‌اند و همچنین دقیقاً ۲۵ سفیدپوست و ۲۵ سیاه‌پوست استخدام شده‌اند). اما روی زیرگروه‌های تقاطعی اصلاً رعایت نشده است (چون نرخ استخدام در مردان سیاه‌پوست و زنان سفیدپوست صفر است درحالی‌که نرخ استخدام در مردان سفیدپوست و زنان سیاه‌پوست ۱۰۰ درصد است).

این مثال نشان داد که بررسی تک‌بعدی ویژگی‌های حاشیه‌ای کافی نیست، زیرا مدل‌های پیچیده می‌توانند تبعیض را در لایه‌های تقاطعی پنهان کنند. به عبارت دیگر، ممکن است مدل در آمار کلی و مجزا نسبت به دو گروه متفاوت (مثلاً نژاد و جنسیت) کاملاً منصفانه رفتار کند، اما در محل تقاطع آن‌ها (مثلاً گروه زنان سیاه‌پوست) به شدت تبعیض‌آمیز عمل کرده و این بی‌عدالتی را در دل آمار کلی پنهان شود.

از سوی دیگر، نمی‌توان به سادگی تمام زیرگروه‌های تقاطعی را محاسبه کرد زیرا با ترکیب ویژگی‌ها، تعداد زیرگروه‌ها به شدت افزایش می‌یابد. این تعدد زیرگروه‌ها باعث می‌شود داده‌ها آن‌قدر خرد شوند که در هر زیرگروه تنها چند نمونه محدود باقی بماند؛ در نتیجه، محاسبه آماری نرخ خطا روی آن‌ها بی‌معنی شده و اعمال شروط ریاضی انصاف برای همه آن‌ها عملاً غیرممکن می‌گردد.

ب) اعمال اجباری برابری جمعیتی در اعطای وام، سیستم مالی را مجبور می‌کند تا آستانه تایید وام را برای گروه حاشیه‌ای پایین بیاورد تا نرخ تایید آن‌ها با گروه دیگر برابر شود. حلقه بازخورد در این فرآیند به این شکل عمل می‌کند که با کاهش آستانه قبولی، وام به افراد پرریسکی از گروه اقلیت تخصیص می‌یابد که احتمال عدم توانایی آن‌ها در بازپرداخت بالا است. از نظر اعتباری، افت نمره ناشی از عدم بازپرداخت یک وام، بسیار شدیدتر و مخرب‌تر از افزایش نمره ناشی از پرداخت موفقیت‌آمیز آن است. در نتیجه پس از گذشت یک دوره زمانی، تعداد زیادی از این افراد دچار سقوط شدید نمره اعتباری می‌شوند. این چرخه باعث می‌شود که میانگین نمره اعتباری و رفاه اقتصادی کل گروه حاشیه‌ای، نسبت به حالت پیش از مداخله منصفانه، به شدت کاهش یابد.

این پدیده ثابت می‌کند که ارزیابی یک مداخله منصفانه صرفاً به صورت ایستا و در لحظه تصمیم‌گیری (لحظه تخصیص وام) رویکردی گمراه‌کننده است. گرچه ممکن است این مداخله در یک مقطع زمانی خاص و بر اساس فرمول‌های آماری عادلانه به نظر می‌رسد، اما می‌تواند پیامدهای مخربی داشته باشد و اتفاقاً به همان گروهی که قرار بود انصاف را در حق آنها رعایت کند، آسیب برساند. بنابراین، برای سنجش واقعی عدالت، باید سیستم را به صورت پویا ارزیابی کرد و تأثیرات بلندمدت و اثرات آینده‌ی تصمیمات مدل را بر رفاه واقعی افراد مورد سنجش قرار داد.

بخش سوم: پیاده‌سازی و تحلیل تجربی

مرحله ۰ - بازتولیدپذیری

کد این بخش در فایل Q1.ipynb در فلدر Q1 موجود است و نتیجه به صورت زیر است:

```
Training data size: 4937
Testing data size: 1235
Train/Test Split: 80% / 20%
```

شکل ۱ - تعداد داده‌های train و test و نسبت آنها

مرحله ۱ - ممیزی سوگیری


کد این بخش در فایل Q1.ipynb در فلدر Q1 موجود است و نتایج به صورت زیر است:

(الف)

```
Base Rates (P(Y=1)) by Race:
race
African-American    0.522494
Native American    0.500000
Caucasian           0.394391
Other               0.381295
Hispanic            0.346988
Asian               0.291667
```

شکل ۲ - نرخ پایه گروه‌ها

(ب)



شکل ۳ - توزیع امتیاز دهکی به تفکیک گروه

(ج)

```
Proxy Strength for race:
decile_score           0.307519
priors_count           0.206501
age                    0.182453
c_charge_degree_F      0.112479
c_charge_degree_M      0.112479
sex_Male               0.082964
sex_Female             0.082964
days_b_screening_arrest 0.078932
dtype: float64
```

شکل ۴ - قدرت پراکسی‌ها در پیش‌بینی race

تحلیل همبستگی نشان می‌دهد که ویژگی‌هایی مانند امتیاز ارزیابی (decile_score)، تعداد سوءپیشینه (priors_count) و سن (age)، ارتباط غیرمستقیم و معناداری (به عنوان پراکسی) با ویژگی حساس نژاد دارند.

ارتباط این یافته با پرسش ۳- (ب) در اثبات ناکارآمدی رویکرد انصاف از طریق ناآگاهی است. در این رویکرد تصور می‌شود که اگر صرفاً ستون مربوط به ویژگی حساس (نژاد) از داده‌های آموزش حذف شود، مدل نسبت به نژاد نابینا شده و منصفانه عمل خواهد کرد. با این حال، وجود این پراکسی‌ها ثابت می‌کند که الگوریتم‌های یادگیری ماشین می‌توانند به راحتی اطلاعات نژادی را از طریق ترکیب سایر متغیرهای به ظاهر خنثی بازسازی کنند و بازهم عدالت مدل را تحت تأثیر قرار دهند.

د) ممیزی انجام‌شده به وضوح نشان می‌دهد که داده‌های آموزشی ما بی‌طرف نیستند و بازتابی از سوگیری‌های جامعه‌اند. وجود تفاوت آشکار در نرخ‌های پایه و پراکسی‌های قوی برای نژاد، ثابت می‌کند که هر مدل استاندارد که بر پایه این داده‌ها ساخته شود، این نابرابری‌ها را به عنوان الگو یاد گرفته و تبعیض را بازتولید و تشدید می‌کند.

علاوه بر این، به دلیل تفاوت معنادار همین نرخ‌های پایه، برآورده کردن هم‌زمان معیارهای مختلف انصاف از نظر ریاضی کاملاً غیرممکن است. و همچنین، رویکردهای ساده‌انگارانه مانند حذف ستون نژاد به دلیل وجود پراکسی‌ها با شکست مواجه می‌شوند. این داده‌ها ثابت می‌کنند که استفاده از مدل‌های معمولی مردود است و ما به اعمال تکنیک‌های تخصصی و مداخلات ریاضی برای رسیدن به حد خوبی از انصاف نیاز داریم.

مرحله ۲ – مدل پایه و سنجه‌های دست‌ساز

الف) کد این بخش در فایل Q1.ipynb در فلدر Q1 موجود است و نتیجه به صورت زیر است:

```
----- Baseline Model Performance -----  
Accuracy: 0.6826  
ROC-AUC: 0.7272
```

شکل ۵ – دقت و ROC-AUC کلی مدل

ب و ج) کد این بخش‌ها در فایل Q1.ipynb در فلدر Q1 موجود هستند و نتیجه به صورت زیر است:

----- Metrics by Group -----				
	Demographic Parity	TPR	FPR	PPV
race				
African-American	0.5164	0.6884	0.3257	0.7009
Asian	0.0000	0.0000	0.0000	0.0000
Caucasian	0.2365	0.3975	0.1391	0.6337
Hispanic	0.2128	0.3111	0.1224	0.7000
Native American	1.0000	0.0000	1.0000	0.0000
Other	0.1077	0.2778	0.0426	0.7143
----- Inter-Group Gaps (African-American vs Caucasian) -----				
Demographic Parity Gap	0.2798			
TPR Gap	0.2909			
FPR Gap	0.1866			
PPV Gap	0.0672			

شکل ۶ - سنجه‌ها به تفکیک گروه و به صورت شکاف بین گروهی

همانطور که در تصویر مشخص است، سنجه‌ها برای تمام گروه‌ها گزارش شده است و شکاف بین گروهی نیز برای دو گروه اصلی مورد مناقشه (یعنی African-American و Caucasian) گزارش شده است. همچنین کد پیاده‌سازی سنجه‌ها نیز به صورت زیر است (این کد در فایل نیز قابل مشاهده است):

```
def calculate_metrics(group):
    y_t = group["y_true"]
    y_p = group["y_pred"]

    TP = ((y_t == 1) & (y_p == 1)).sum()
    FP = ((y_t == 0) & (y_p == 1)).sum()
    TN = ((y_t == 0) & (y_p == 0)).sum()
    FN = ((y_t == 1) & (y_p == 0)).sum()

    dp = y_p.mean()
    tpr = TP / (TP + FN) if (TP + FN) > 0 else 0
    fpr = FP / (FP + TN) if (FP + TN) > 0 else 0
    ppv = TP / (TP + FP) if (TP + FP) > 0 else 0

    return pd.Series({"Demographic Parity": dp, "TPR": tpr, "FPR": fpr, "PPV": ppv})
```

شکل ۷ - کد پیاده‌سازی سنجه‌ها

مرحله ۳ - آزمون «انصاف از طریق ناآگاهی»

کد این بخش در فایل Q1.ipynb در فلدر Q1 موجود است و نتیجه به صورت زیر است:

----- Metrics by Group (Unaware Model) -----				
	Demographic Parity	TPR	FPR	PPV
race				
African-American	0.4867	0.6588	0.2961	0.7115
Asian	0.1429	1.0000	0.0000	1.0000
Caucasian	0.2342	0.3913	0.1391	0.6300
Hispanic	0.2872	0.3778	0.2041	0.6296
Native American	1.0000	0.0000	1.0000	0.0000
Other	0.2154	0.4444	0.1277	0.5714
----- Inter-Group Gaps (African-American vs Caucasian) -----				
Demographic Parity Gap	0.2525			
TPR Gap	0.2674			
FPR Gap	0.1570			
PPV Gap	0.0815			

شکل ۸ - سنج‌ها به تفکیک گروه پس از حذف متغیر حساس

همانطور که مشخص است، اختلاف‌ها همچنان به شکل معناداری باقی می‌مانند و از بین نرفته‌اند. با وجود اینکه مدل کاملاً نسبت به متغیر نژاد ناآگاه شده است، اما نتایج نشان می‌دهد که در میان بعضی گروه‌ها، همچنان اختلافات زیادی در سنج‌ها وجود دارد. مثلاً نرخ خطای مثبت کاذب (FPR) در گروه سیاه‌پوستان (African-American) بیش از دو برابر این مقدار در گروه سفیدپوستان (Caucasian) است.

دلیل این رفتار، وجود پراکسی‌ها یا متغیرهای جایگزین در مجموعه داده است. ویژگی‌های دیگری مانند «تعداد سوءپیشینه‌های قبلی» یا «سن»، همبستگی آماری پنهان اما قدرتمندی با متغیر نژاد دارند. در نتیجه، حتی وقتی ستون نژاد را حذف می‌کنیم، مدل به راحتی الگوی نژادی را از طریق ترکیب این متغیرهای باقی‌مانده بازسازی می‌کند و همان رفتار تبعیض‌آمیز را از مسیرهای غیرمستقیم یاد می‌گیرد. این خروجی‌ها این کج‌فهمی را ثابت می‌کنند که حذف کردن نام متغیر حساس، به معنای حذف شدن سوگیری ساختاری درون داده‌ها نیست.

مرحله ۴ - تعدیل و مقایسه

کد این بخش در فایل Q1.ipynb در فلدر Q1 موجود است و نتیجه به صورت زیر است:

----- Base Model Metrics -----					
	Demographic Parity	TPR	FPR	PPV	
race					
African-American	0.5164	0.6884	0.3257	0.7009	
Asian	0.0000	0.0000	0.0000	0.0000	
Caucasian	0.2365	0.3975	0.1391	0.6337	
Hispanic	0.2128	0.3111	0.1224	0.7000	
Native American	1.0000	0.0000	1.0000	0.0000	
Other	0.1077	0.2778	0.0426	0.7143	
----- In-Processing Metrics (Exponentiated Gradient) -----					
	Demographic Parity	TPR	FPR	PPV	
race					
African-American	0.3651	0.5312	0.1809	0.7650	
Asian	0.1429	0.0000	0.1667	0.0000	
Caucasian	0.3255	0.5031	0.2180	0.5827	
Hispanic	0.3830	0.5111	0.2653	0.6389	
Native American	0.0000	0.0000	0.0000	0.0000	
Other	0.3077	0.5000	0.2340	0.4500	
----- Post-Processing Metrics (Threshold optimization) -----					
	Demographic Parity	TPR	FPR	PPV	
race					
African-American	0.5055	0.6677	0.3257	0.6944	
Asian	0.2857	1.0000	0.1667	0.5000	
Caucasian	0.4145	0.5963	0.3045	0.5424	
Hispanic	0.4149	0.5111	0.3265	0.5897	
Native American	0.0000	0.0000	0.0000	0.0000	
Other	0.3692	0.5000	0.3191	0.3750	

شکل ۹ - سنجه‌ها به تفکیک گروه و روش‌های تعدیل

----- Final Comparison Table (Gaps: African-American vs Caucasian) -----			
	Baseline	Exponentiated Gradient	Threshold optimization
Accuracy	0.6826	0.6664	0.6567
Dem Parity Gap	0.2798	0.0325	0.0660
TPR Gap	0.2909	0.0370	0.0325
FPR Gap	0.1866	0.0559	0.0085
PPV Gap	0.0672	0.2054	0.1468

شکل ۱۰ - جدول مقایسه‌ای سنجه‌ها بین روش‌های تعدیل


در تحلیل هدف این دو روش، مشاهده می‌کنیم که الگوریتم حین‌پردازش (Exponentiated Gradient) به طور صریح روی مفهوم «برابری جمعیتی» متمرکز بوده تا درصد انتخاب افراد پرخطر در نژادهای مختلف متعادل شود. در مقابل، الگوریتم پس‌پردازش (Threshold Optimization) با هدف‌گذاری روی مفهوم

«برابری شانس‌ها»، تلاش کرده تا خطاهای سیستم، به ویژه شکاف نرخ مثبت کاذب (FPR) و نرخ مثبت واقعی (TPR) را بین گروه‌های نژادی همسو و برابر کند.

از منظر تغییرات رخ داده، هر دو مدل در رسیدن به اهداف اولیه خود بسیار موفق عمل کردند؛ به طوری که هر دو روش شکاف برابری جمعیتی، شکاف FPR و شکاف TPR را به شدت کاهش دادند. با این وجود، مطابق با تئوری عدم امکان، این دستاوردها باعث شد تا تعادل در بخش‌های دیگر به هم بخورد و شکاف ارزش پیش‌بینی مثبت (PPV) به شدت بدتر شود. همچنین مجبور شدیم تا از دقت مدل هزینه بدهیم. به طوری که دقت ۶۸.۲ درصدی مدل پایه، در روش‌های حین‌پردازش و پس‌پردازش به ترتیب به ۶۶.۶ و ۶۵.۶ درصد کاهش یافت. این همان بده‌بستان میان دقت و انصاف است.

مرحله ۵ – عدم امکان تجربی و مرز بده‌بستان

الف) کد این بخش در فایل Q1.ipynb در فلدر Q1 موجود است و نتیجه به صورت زیر است:



شکل ۱۱ – منحنی trade-off دقت و انصاف

همانطور که مشخص است این منحنی برای سنجش FPR رسم شده است و نشان می‌دهد که با کاهش شکاف FPR، یعنی با افزایش انصاف، دقت مدل کاهش می‌یابد.

نکته: این نمودار فقط از روی بهترین و بهینه‌ترین حالت‌ها رسم شده است. یعنی نقطه‌هایی روی این خط قرار گرفته‌اند که در آن‌ها، رسیدن به انصاف بیشتر غیرممکن است، مگر اینکه مجبور شویم دقت کل مدل را پایین بیاوریم. این نقاط در شکل آبی هستند و سایر نقاط خاکستری هستند.

ب) کد این بخش در فایل Q1.ipynb در فلدر Q1 موجود است و نتیجه به صورت زیر است:

```
----- Race: African-American -----
Base Rate (p): 0.5257
LHS (Actual FPR): 0.3257
RHS (Calculated): 0.3257
Difference: 0.0000

----- Race: Caucasian -----
Base Rate (p): 0.3770
LHS (Actual FPR): 0.1391
RHS (Calculated): 0.1391
Difference: 0.0000
```

شکل ۱۲ - بررسی کمی اتحاد چولدچوا

همان‌طور که در خروجی بالا مشاهده می‌شود، مقدار اختلاف (Difference) دو طرف اتحاد برای هر دو گروه نزدیکی دقیقاً برابر با صفر است. این نتیجه به صورت تجربی تأیید می‌کند که سمت چپ و راست اتحاد با هم برابرند و در نتیجه اتحاد پرسش ۲ برقرار است و داده‌ها مطابق پیش‌بینی نظریه رفتار می‌کنند.

با استناد به همین خروجی، قضیه عدم امکان به سادگی اثبات می‌شود. همان‌طور که می‌بینیم، نرخ پایه (p) برای گروه آفریقایی-آمریکایی (۰.۵۲۵۷) با گروه قفقازی (۰.۳۷۷۰) متفاوت است؛ بنابراین ترم اول سمت راست معادله یعنی $\frac{p}{1-p}$ در این دو گروه نابرابر است.

حال اگر ما بخواهیم با الگوریتم‌های تنظیم انصاف، شکاف فرصت برابر و شکاف ارزش پیش‌بینی مثبت را همزمان به صفر برسانیم (یعنی متغیرهای PPV و FNR در ترم‌های دوم و سوم را برای هر دو گروه مساوی کنیم)، به دلیل تفاوت در ترم اول، حاصل ضرب کل سمت راست (RHS) به ناچار در دو گروه متفاوت خواهد شد. از آنجا که تساوی دو طرف معادله قطعی است، پس سمت چپ معادله، یعنی FPR هم باید در دو گروه متفاوت باشد.

اگر هر دو سنجه دیگری از این ۳ سنجه را برابر کنیم، با توجه به تفاوت در نرخ‌های پایه باز هم استدلال فوق صادق است و سنجه سوم نمی‌تواند برابر باشد.

مرحله ۶ – ممیزی تقاطعی

کد این بخش در فایل Q1.ipynb در فلدر Q1 موجود است و نتیجه به صورت زیر است:

----- All Intersectional Subgroups -----				
	Demographic Parity	TPR	FPR	PPV
race_sex				
African-American - Female	0.1466	0.3023	0.0548	0.7647
African-American - Male	0.4190	0.5748	0.2208	0.7682
Asian - Male	0.2857	0.0000	0.3333	0.0000
Caucasian - Female	0.1163	0.2500	0.0370	0.8000
Caucasian - Male	0.3930	0.5659	0.2877	0.5448
Hispanic - Female	0.1111	0.1000	0.1250	0.5000
Hispanic - Male	0.4079	0.5143	0.3171	0.5806
Native American - Male	0.0000	0.0000	0.0000	0.0000
Other - Female	0.0000	0.0000	0.0000	0.0000
Other - Male	0.3077	0.5000	0.2059	0.5625
----- Intersectional Subgroups in African-American & Caucasian -----				
	Demographic Parity	TPR	FPR	PPV
race_sex				
African-American - Female	0.1466	0.3023	0.0548	0.7647
African-American - Male	0.4190	0.5748	0.2208	0.7682
Caucasian - Female	0.1163	0.2500	0.0370	0.8000
Caucasian - Male	0.3930	0.5659	0.2877	0.5448

شکل ۱۳ – سنجش‌ها در زیرگروه‌های تقاطعی

در ممیزی این مرحله، ما مدل حین‌پردازش (Exponentiated Gradient) را به عنوان بهترین مدل انتخاب کردیم. زیرا در مرحله ۴ توانسته بود شکاف‌ها را با حفظ دقت معقول، بسیار کاهش دهد.

همان‌طور که در تصویر مشخص است، خروجی برای شفافیت بیشتر در دو بخش ارائه شده است. یک جدول کلان برای تمامی ترکیب‌های نژاد و جنسیت، و یک جدول متمرکز برای بررسی دقیق‌تر دو گروه اصلی (آفریقایی-آمریکایی و قفقازی).

داده‌های این جدول به وضوح نشان می‌دهند که انصاف حاشیه‌ای (برابری بین نژادها) تقریباً برقرار بوده ولی انصاف تقاطعی نقض شده است و پدیده دستکاری زیرگروهی قطعاً اتفاق افتاده است.

با وجود اینکه مدل در ظاهر میانگین نژادها را برابر کرده بود، اما جدول زیرگروه‌ها نشان می‌دهد که این تعادل با اعمال تبعیض شدید جنسیتی درون هر نژاد به دست آمده است. به عنوان مثال، نرخ مثبت کاذب (FPR) برای مردان سیاه‌پوست (۰.۲۲۰۸) دقیقاً ۴ برابر زنان سیاه‌پوست (۰.۰۵۴۸) است. این شکاف عظیم به شکلی مشابه در میان مردان و زنان سفیدپوست (۰.۲۸۷۷ در برابر ۰.۰۳۷۰) نیز تکرار شده است.

در واقع، الگوریتم برای اینکه از نظر ریاضی شرطِ برابری نژادی را ارضا کند، مردان را در هر دو گروه به شدت قربانی کرده و به زنان ارفاق کرده است تا میانگین کل گروه متعادل به نظر برسد. این جدول ثابت می‌کند که منصف بودن مدل در یک ویژگی کلی (مثل نژاد)، به هیچ وجه تضمین‌کننده رفتار عادلانه در زیرگروه‌های تقاطعی (مثل نژاد $\times$ جنسیت) نیست.

سوال دوم: حریم خصوصی در یادگیری ماشین و یادگیری فدرال

بخش اول: سؤالات توضیحی

زیربخش اول: حساسیت و مکانیزم لاپلاس

الف) حساسیت (l_1) برابر است با بیشترین میزان تغییری که با تغییر داده‌های تنها یک خانوار در خروجی ایجاد می‌شود.

- q_1 : از آنجا که بازه مصرف هر خانوار بین ۰ تا ۱۰۰ است، تغییر داده‌های یک خانوار مجموع را نهایتاً ۱۰۰ واحد تغییر می‌دهد. با توجه به وجود ۱۰۰۰ خانوار در داده‌ها، بیشترین تغییر در میانگین برابر است با:

$$l_1(q_1) = 100/1000 = 0.1$$

- q_2 : با تغییر داده‌های یک خانوار، مجموع مصرف کل نهایتاً می‌تواند به اندازه ماکزیمم مصرف یک خانوار تغییر کند. بنابراین:

$$l_1(q_2) = 100$$

- q_3 : هر خانوار حداکثر در ۲ الگو حضور دارد. در بدترین حالت، یک خانوار از ۲ الگو حذف شده و به ۲ الگوی کاملاً متفاوت اضافه می‌شود. بنابراین در بردار خروجی، دو درایه به اندازه ۱- و دو درایه دیگر به اندازه ۱+ تغییر می‌کنند. مجموع قدر مطلق این تغییرات برابر است با:

$$l_1(q_3) = |-1| + |-1| + |1| + |1| = 4$$

ب) پارامتر b مکانیزم لاپلاس از رابطه $b = l_1/\epsilon$ به دست می‌آید. با فرض $\epsilon = 0.2$ برای هر درخواست داریم:

- برای درخواست q_1 :

$$b_1 = 0.1/0.2 = 0.5$$

- برای درخواست q_2 :

$$b_2 = 100/0.2 = 500$$

- برای درخواست q_3 :

$$b_3 = 4/0.2 = 20$$

زیربخش دوم: انتشار خصوصی داده‌ها و Report Noisy Max

الف) ناسازگاری به این دلیل رخ می‌دهد که در مکانیزم‌های حریم خصوصی تفاضلی، به هر درخواست به صورت کاملاً مستقل نویز اضافه می‌شود. در دنیای واقعی، برخی از داده‌ها مثل میانگین و مجموع کل ماهیتاً به هم وابسته‌اند و یک رابطه قطعی (مجموع برابر است با میانگین ضربدر تعداد) بین آن‌ها برقرار است. با اضافه شدن نویزهای مستقل، این رابطه ریاضی شکسته می‌شود. برای مثال با توجه به داده‌های سوال، میانگین نویزی و منتشر شده برابر است با 37.5 به علاوه 1.8 که می‌شود 39.3 . مجموع نویزی و منتشر شده نیز برابر است با 37500 منهای 920 که می‌شود 36580 . حالا اگر میانگین نویزی یعنی 39.3 را در تعداد خانوارها که 1000 است ضرب کنیم، به عدد 39300 می‌رسیم. این عدد با مجموع منتشر شده یعنی 36580 تفاوت دارد و نشان‌دهنده ناسازگاری است.

برای رفع ناسازگاری، به جای گزارش مستقیم مقادیر نویزی، می‌توانیم از روش ترکیب تخمین‌ها استفاده کنیم. ما اکنون دو تخمین یا حدس مختلف برای مجموع کل مصرف داریم. حدس اول همان مقدار نویزی مجموع است یعنی 36580 . حدس دوم از روی مقدار نویزی میانگین به دست می‌آید؛ یعنی میانگین نویزی ضربدر تعداد خانوارها که می‌شود 39300 . چون هر دو عدد دارای نویز هستند و ارزش اطلاعاتی دارند، می‌توانیم برای رسیدن به یک عدد واحد و سازگار، از این دو تخمین میانگین‌گیری کنیم. مثلاً اگر میانگین ساده بگیریم، مجموع نهایی سازگار برابر می‌شود با 37940 . سپس میانگین سازگار را از روی همین مجموع جدید به دست می‌آوریم. یعنی 37940 تقسیم بر 1000 که می‌شود 37.94 . (پس یک نویز جدید برای میانگین بدست می‌آید). با این تکنیک پس‌پردازش، خروجی‌هایی تولید می‌کنیم که هم از نظر ریاضی با هم سازگارند و هم دقت بهتری نسبت به مقادیر اولیه دارند.

ب) برای محاسبه پارامتر b در مکانیزم لاپلاس، باید میزان حساسیت را بر مقدار اپسیلون تقسیم کنیم. همان‌طور که در زیربخش قبل محاسبه کردیم، حساسیت برای درخواست بردار شمارش الگوها برابر با 4 است. با توجه به اینکه مقدار اپسیلون برابر با 0.4 داده شده است، محاسبه بر اساس فرمول زیر انجام می‌شود:

$$b = \frac{l_1}{\epsilon} = \frac{4}{0.4} = 10$$

بنابراین مقدار نهایی برای این پارامتر برابر با 10 خواهد بود.

ج) در الگوریتم Report Noisy Max، تغییر داده‌های یک خانوار تنها می‌تواند تعداد یک الگو را حداکثر یک واحد تغییر دهد، بنابراین حساسیت (l_1) برابر 1 است. با توجه به $\epsilon = 0.4$ ، scale نویز لاپلاس به شکل زیر محاسبه می‌شود:

$$Scale = b = \frac{l_1}{\epsilon} = \frac{1}{0.4} = 2.5$$

تعیین خروجی الگوریتم:

برای یافتن خروجی، مقادیر نویز را با مقادیر واقعی هر الگو جمع می‌کنیم:

$$\text{الگوی اول: } 310 - 4 = 306$$

$$\text{الگوی دوم: } 295 + 18 = 313$$

$$\text{الگوی سوم: } 180 + 9 = 189$$

$$\text{الگوی چهارم: } 160 - 6 = 154$$

$$\text{الگوی پنجم: } 90 + 21 = 111$$

$$\text{الگوی ششم: } 75 + 2 = 77$$

از آنجا که بیشترین مقدار پس از اعمال نویز برابر ۳۱۳ است، الگوریتم «الگوی دوم» را به عنوان خروجی اعلام می‌کند.

الگوی انتخاب شده (الگوی دوم) با الگوی واقعاً پرتکرار (الگوی اول) یکسان نیست. این نتیجه به روشنی Trade-off میان privacy و utility را نشان می‌دهد؛ سیستم برای افزایش privacy کاربران مجبور به تزریق نویز شد و باعث شد الگوریتم در یافتن بیشینه واقعی دچار خطا شود. بنابراین با انجام این کار باعث شد که دقت مدل و در نتیجه utility کاهش یابد. پس میان privacy و utility یک trade-off وجود دارد.

زیربخش سوم: تخصیص بودجه حریم خصوصی و ترکیب مکانیزم‌ها

الف) با توجه به بودجه کل که $\epsilon = 0.6$ است، می‌توانیم تخصیص را به عنوان یک پیشنهاد منطقی به شکل زیر انجام دهیم:

$$\text{میانگین مصرف: } \epsilon = 0.3$$

$$\text{پرتکرارترین الگوی مصرف: } \epsilon = 0.15$$

$$\text{بردار شمارش: } \epsilon = 0.15$$

بر اساس اصول حریم خصوصی، میزان نویز اضافه شده به خروجی با بودجه اپسیلون اختصاص یافته به آن رابطه عکس دارد. یعنی هرچه سهم بودجه بیشتری به یک درخواست تخصیص یابد، نویز کمتری به آن

اعمال شده و در نتیجه دقت خروجی آن بالاتر می‌رود. از آنجا که صورت سوال تاکید دارد دقت میانگین مصرف از دو خروجی دیگر مهم‌تر است، بیشترین سهم از کل بودجه به آن اختصاص داده شد تا کمترین نویز را دریافت کند. باقیمانده بودجه نیز بین دو درخواست دیگر تقسیم می‌شود.

ب) برای محاسبه این پارامتر، از میزان حساسیتی که در زیربخش اول برای میانگین مصرف به دست آوردیم (یعنی ۰.۱) و میزان بودجه‌ای که در قسمت الف برای آن پیشنهاد دادیم (یعنی ۰.۳) استفاده می‌کنیم:

$$b = \frac{l_1}{\epsilon} = \frac{0.1}{0.3} \approx 0.333$$

بنابراین، پارامتر b برای مکانیزم لاپلاس مربوط به میانگین مصرف تقریباً برابر با ۰.۳۳۳ خواهد بود.

ج) همان‌طور که قبلاً بررسی شد، تغییر داده‌های یک خانوار در بدترین حالت باعث می‌شود دو درایه از بردار شمارش به اندازه یک واحد کاهش (منفی یک) و دو درایه به اندازه یک واحد افزایش (مثبت یک) یابند. حساسیت ال ۲ از جذر مجموع مربعات این تغییرات محاسبه می‌شود:

$$l_2 = \sqrt{(-1)^2 + (-1)^2 + (+1)^2 + (+1)^2} = \sqrt{4} = 2$$

بنابراین حساسیت ال ۲ برای این بردار برابر با ۲ است.

با توجه به صورت سوال، مقدار دلتا برابر با 10^{-5} در نظر گرفته شده است. ابتدا با استفاده از فرمول داده شده، کمترین مقدار c را محاسبه می‌کنیم:

$$c^2 = 2 \ln\left(\frac{1.25}{10^{-5}}\right) = 2 \ln(125000) \approx 2 \times 11.736 = 23.472$$

با جذر گرفتن از مقدار بالا، مقدار ثابت c به دست می‌آید:

$$c \approx \sqrt{23.472} \approx 4.845$$

اکنون با در اختیار داشتن مقادیر c ، حساسیت l_2 و ϵ پیشنهادی در قسمت الف (یعنی ۰.۱۵)، حداقل مقدار σ را برای مکانیزم گاوسی محاسبه می‌کنیم:

$$\sigma = \frac{c \times l_2}{\epsilon} = \frac{4.845 \times 2}{0.15} = \frac{9.69}{0.15} = 64.6$$

بنابراین حداقل مقدار انحراف معیار (σ) برای نویز گاوسی در این بخش، تقریباً برابر با ۶۴.۶ خواهد بود.

د) بر اساس قانون composition در حریم خصوصی، زمانی که چندین مکانیزم به صورت مستقل روی یک مجموعه داده اجرا می‌شوند، افت حریم خصوصی (Privacy Loss) کلی برابر با مجموع بودجه‌های مصرف شده در هر اجرا است. از آنجا که مجموع بودجه مصرفی در هر روز برابر با ۰.۶ است، افت حریم خصوصی برای هفت روز متوالی به شکل زیر محاسبه می‌شود:

$$\text{Total Privacy Loss} = 7 \times 0.6 = 4.2$$

بنابراین، privacy loss کل هفته برابر با ۴.۲ خواهد بود.

اگر بخواهیم افت حریم خصوصی کل هفته همچنان روی سقف حداکثر ۰.۶ باقی بماند، باید این بودجه کلی را بین هفت روز کاری تقسیم کنیم. بنابراین، بودجه مجاز روزانه کاهش یافته و به مقدار زیر می‌رسد.

$$\epsilon = \frac{0.6}{7} \approx 0.0857$$

پس بودجه کل روزانه جدید برابر با ۰.۰۸۵۷ خواهد بود.

اثر تغییر بودجه بر روی سودمندی:

همان‌طور که در روابط ریاضی مکانیزم‌های لاپلاس و گاوسی مشخص است، میزان بودجه با مقیاس نویز رابطه عکس دارد (بودجه در مخرج کسر قرار دارد). با کاهش شدید بودجه روزانه از ۰.۶ به حدود ۰.۰۸، سیستم مجبور است نویز بسیار بزرگ‌تری را به داده‌های هر روز تزریق کند. در نتیجه این کار، حریم خصوصی حفظ می‌شود اما utility و دقت گزارش‌های روزانه به شدت افت کرده و کارایی خود را از دست می‌دهند.

زیربخش اول: حریم خصوصی، استحکام و یادگیری فدرال

الف) خیر، یادگیری فدرال به طور ذاتی و بدون استفاده از مکانیزم‌های تکمیلی، یک فناوری حفظ حریم خصوصی کامل محسوب نمی‌شود. اگرچه در این روش داده‌های خام روی دستگاه شرکت‌کنندگان باقی می‌ماند، اما تبادل به‌روزرسانی‌های مدل به تنهایی مصون از آسیب‌پذیری نیست و می‌تواند منجر به نشت اطلاعات حساس از طریق حملاتی مانند membership inference و property inference شود.

میان بهبود عملی و تضمین رسمی حریم خصوصی در بستر یادگیری فدرال تفاوت‌هایی وجود دارد. مفهوم بهبود عملی حریم خصوصی به ساختار پایه‌ای یادگیری فدرال اشاره دارد که در آن از تجمیع داده‌های خام کاربران در یک سرور مرکزی جلوگیری می‌شود و تنها پارامترهای مدل تبادل می‌گردند. این رویکرد در عمل حریم خصوصی را نسبت به یادگیری متمرکز افزایش می‌دهد اما نمی‌تواند نشت اطلاعات از طریق خود پارامترهای تجمیع‌شده را به طور کامل مسدود کند.

مفهوم تضمین رسمی حریم خصوصی نیازمند چارچوب‌های اثبات‌شده‌ای مانند حریم خصوصی تفاضلی است که با افزودن نویز، یک حد بالای آماری و قطعی برای میزان اطلاعاتی که یک مهاجم می‌تواند استنتاج کند ارائه می‌دهد. تضمین رسمی به صورت ریاضی و قطعی اطمینان حاصل می‌کند که حضور یا عدم حضور داده‌های یک فرد، تأثیر قابل تشخیصی بر خروجی نهایی الگوریتم نخواهد گذاشت.

ب) بر اساس مقاله، حریم خصوصی و استحکام دو هدف کاملاً متمایز در یادگیری فدرال هستند و تمرکز بر یکی، دیگری را تضمین نمی‌کند.

استحکام به معنای محافظت از عملکرد و دقت مدل در برابر حملات مسموم‌سازی و backdoor است. هدف این است که مهاجم نتواند با تزریق داده‌ها یا به‌روزرسانی‌های مخرب، باعث رفتار اشتباه مدل در وظایف خاص یا کاهش دقت کلی آن شود.

حریم خصوصی به معنای جلوگیری از نشت اطلاعات حساس داده‌های آموزشی است. هدف این است که مهاجم نتواند از طریق بررسی مدل یا به‌روزرسانی‌های آن، به اطلاعات خصوصی افراد دست پیدا کند.

این دو هدف لزوماً یکدیگر را پوشش نمی‌دهند زیرا مکانیزم‌های مقابله با آن‌ها متفاوت است. مقاله به صراحت نشان می‌دهد که بسیاری از روش‌های دفاعی طراحی شده برای استحکام (مانند Norm Bounding)، هیچ‌گونه حریم خصوصی‌ای فراهم نمی‌کنند؛ زیرا در این روش‌ها به‌روزرسانی‌های شرکت‌کنندگان به صورت شفاف و بدون نویز ارسال می‌شود که همین امر منجر به افشای اطلاعات می‌گردد. بنابراین، یک سیستم

می‌تواند در برابر خطاهای عملکردی مستحکم باشد اما به شدت در حفظ حریم خصوصی آسیب‌پذیر عمل کند.

(ج) خیر، نمی‌توان الزاماً چنین ادعایی کرد. بر اساس مقاله، اگرچه سامانه یادگیری فدرال از تجمیع داده‌های خام در سرور جلوگیری می‌کند، اما بدون استفاده از مکانیزم‌های دفاعی قدرتمندی مانند حریم خصوصی تفاضلی، لزوماً محافظت بیشتری برای حریم خصوصی فراهم نمی‌کند.

دلیل این امر آن است که به‌روزرسانی‌های مدل (مانند گرادینت‌ها و وزن‌ها) که به سرور ارسال می‌شوند، همچنان حاوی اطلاعات حساس و نشانه‌های مهمی از داده‌های آموزشی هستند. مقاله به روشنی نشان می‌دهد که یک مهاجم یا حتی یک سرور کنجکاو می‌تواند با تحلیل دقیق همین به‌روزرسانی‌ها، حملات موافقی مانند استنتاج عضویت و استنتاج ویژگی را اجرا کند و به اطلاعات خصوصی افراد حاضر در آموزش مدل پی ببرد. بنابراین، صرف استفاده از مدل فدرال، مانع از نشت اطلاعات نمی‌شود و برای تضمین امنیت، سیستم نیازمند مکانیزم‌های دفاعی تکمیلی است.

زیربخش دوم: حملات حریم خصوصی و مسموم‌سازی در یادگیری فدرال

الف) به طور کلی می‌توانیم براساس هدف نهایی حمله، دو دسته‌بندی کلی در نظر بگیریم:

دسته اول: حملات علیه Robustness (استحکام مدل)

هدف این حملات تخریب عملکرد مدل یا ایجاد خطای عمدی در پیش‌بینی‌ها است.

حمله data poisoning: در این دسته قرار می‌گیرد زیرا مهاجم با دستکاری یا تزریق داده‌های مخرب به مجموعه آموزشی پیش از آغاز یادگیری، فرآیند آموزش را مختل می‌کند تا دقت کلی مدل کاهش یابد.

حملات model poisoning و backdoor: به این دلیل در این دسته هستند که در فضای یادگیری فدرال، مهاجم مستقیماً به‌روزرسانی‌ها و وزن‌های ارسالی به سرور را مسموم می‌کند تا مدل تجمیع‌شده در برابر ورودی‌های خاصی رفتار اشتباه و از پیش تعیین‌شده‌ای نشان دهد.

حملات FGSM و PGD: در این دسته قرار می‌گیرند زیرا هدفشان فریب دادن مدل در مرحله استنتاج یا تست است. مهاجم با اضافه کردن نویزهای کوچک و مهندسی‌شده به داده ورودی، باعث می‌شود مدل خروجی کاملاً اشتباهی تولید کند و به این ترتیب استحکام مدل شکسته می‌شود.

دسته دوم: حملات علیه Privacy (حریم خصوصی)

هدف این حملات استخراج اطلاعات حساس و در واقع مهندسی معکوس مدل بدون تخریب عملکرد آن است.

حمله membership inference: در این دسته قرار می‌گیرد زیرا مهاجم با تحلیل تفاوت در واکنش مدل (مثل تغییرات گرادیان یا میزان خطا)، کشف می‌کند که آیا یک داده خاص در مجموعه آموزشی هدف حضور داشته است یا خیر.

حمله property inference: به این دلیل در این دسته است که مهاجم با بررسی و تحلیل پارامترهای مدل در طول آموزش، ویژگی‌های کلی و پنهان مجموعه آموزشی (مثلاً نژاد افراد در یک مدل تشخیص جنسیت) را که سازنده قصد افشای آن‌ها را نداشته استخراج می‌کند.

حمله model extraction و inversion: در این دسته هستند زیرا مهاجم تلاش می‌کند با ارسال ورودی‌های مختلف و تحلیل خروجی‌ها، داده‌های خام اولیه را بازسازی کند یا پارامترهای خود مدل را کشف کند.

ب) در پارادایم Federated Learning، حمله Model Poisoning تهدیدی بسیار عملی‌تر و خطرناک‌تر محسوب می‌شود که دلیل آن مربوط به ساختار این شبکه‌ها است.

دلیل اول این است که مهاجم با در اختیار داشتن کنترل کامل بر روی فرآیند آموزش محلی، می‌تواند به‌روزرسانی‌ها را دقیقاً برای یک هدف خاص (مانند حملات backdoor) دستکاری کرده و تأثیر آن‌ها را به صورت ریاضی تقویت کند. این کار باعث می‌شود تا آپدیت مخرب او هنگام تجمیع در سرور، بر آپدیت‌های کاربران عادی غلبه کند و تغییرات مستقیماً در مدل نهایی اعمال شود.

دلیل دوم به ناتوانی سرور در بازرسی داده‌ها مربوط می‌شود. در سیستم‌های سنتی، دفاع در برابر مسموم‌سازی معمولاً با بازرسی و پاک‌سازی داده‌های خام آموزشی انجام می‌شود. اما در Federated Learning، یکی از اصول بنیادین این است که سرور تحت هیچ شرایطی حق دسترسی به داده‌های خام کاربران را ندارد تا حریم خصوصی حفظ شود. از آنجا که سرور تنها به‌روزرسانی‌های عددی را دریافت می‌کند و نمی‌تواند داده‌های اصلی پشت آن‌ها را برای یافتن ناهنجاری بررسی کند، استفاده از روش‌های دفاعی مبتنی بر بازرسی داده‌ها غیرممکن می‌شود. در نتیجه، هر هدفی که با مسموم‌سازی داده‌ها قابل دستیابی باشد، با مسموم‌سازی مستقیم مدل به شکلی بسیار مؤثرتر و پنهان‌تر در این سیستم‌ها قابل اجرا است.

ج) مکانیزم حمله Isolating Gradient Ascent

در این روش که یکی از قوی‌ترین حملات از سمت سرور است، سرور به عنوان یک مهاجم، کلاینت هدف را ایزوله می‌کند. مکانیزم حمله به این شکل است که سرور از ارسال مدل تجمیع‌شده واقعی به کلاینت هدف خودداری کرده و در عوض یک دید محلی (local view) و ایزوله‌شده از فرآیند آموزش را برای او ایجاد می‌کند. این ایزوله‌سازی باعث می‌شود که مدل محلی کلاینت نتواند از داده‌های سایرین بهره‌برد؛ در نتیجه، مدل آن کلاینت اطلاعات بسیار بیشتری از مجموعه داده‌های آموزشی محلی خود را درون پارامترها و وزن‌ها ذخیره می‌کند. در نهایت، سرور با اعمال حمله Gradient Ascent بر روی این کلاینت ایزوله‌شده، اطلاعات حساس او را به راحتی استخراج می‌نماید.

دیدگاه ریاضی و رفتار تابع زیان در الگوریتم SGD:

ایده اصلی حمله به این شکل است که سرور پیش از ارسال مدل به کلاینت، الگوریتم Gradient Ascent را روی یک داده هدف اجرا می‌کند. با این کار، سرور، پارامترها و وزن‌های مدل را به گونه‌ای دستکاری می‌کند که میزان خطای (loss) آن داده خاص به شدت افزایش یابد.

سپس این مدل دستکاری‌شده برای کلاینت ارسال می‌شود تا فرآیند بهینه‌سازی محلی را انجام دهد. در این مرحله دو حالت رخ می‌دهد. اگر داده هدف واقعاً در مجموعه آموزشی کلاینت وجود داشته باشد (نمونه عضو)، الگوریتم SGD در فرآیند بهینه‌سازی خود با این خطای غیرعادی و بزرگ روبه‌رو می‌شود. از آنجا که وظیفه SGD کمینه کردن Loss Function است، به شدت واکنش نشان داده و برای جبران این خطا، گرادیان بسیار بزرگ و متمایزی تولید می‌کند.

اگر داده هدف در مجموعه کلاینت نباشد (نمونه غیرعضو)، الگوریتم SGD در طول آموزش اصلاً با آن مواجه نمی‌شود که بخواهد خطایش را محاسبه کند؛ بنابراین هیچ واکنش جبرانی نشان نداده و تغییری در گرادیان ایجاد نمی‌کند.

در نهایت، مهاجم (سرور) با دریافت به‌روزرسانی‌های کلاینت و رصد این واکنش‌ها و تغییر ناگهانی گرادیان‌ها، می‌تواند استنتاج کند که آیا داده هدف در مجموعه آموزشی کلاینت حضور داشته است یا خیر.

زیربخش سوم: مکانیزم‌های دفاعی و مبادله حریم خصوصی - استحکام - سودمندی

(۵ سوال این زیربخش، به ترتیب الف تا ه نام‌گذاری شده‌اند.)

الف) در این مقاله، دو مکانیزم زیر به عنوان خط پایه برای مقابله با حملات مسموم‌سازی مدل معرفی شده‌اند:

روش Norm Bounding: در این مکانیزم دفاعی، سرور اندازه یا نرم به‌روزرسانی‌های ارسالی از سوی کلاینت‌ها را بررسی می‌کند تا از یک threshold مشخص فراتر نرود. اگر نرم به‌روزرسانی یک کلاینت از این آستانه بیشتر باشد، سرور آن را scale down می‌کند تا اثر گرادیان‌های بسیار بزرگ و مسموم در مدل نهایی خنثی شود.

روش Weak DP: در این مکانیزم، سرور علاوه بر اعمال Norm Bounding، در هر دور از آموزش، مقداری نویز گاوسی نیز به به‌روزرسانی‌ها اضافه می‌کند تا اثر داده‌های مخرب را بیشتر کاهش دهد. از آنجا که در این روش، تزریق نویز در هر دور به صورت مستقل و بدون کنترل بودجه حریم خصوصی مصرف‌شده در مراحل قبل انجام می‌شود، بر اساس قانون ترکیب (composition)، مقدار نهایی پارامتر epsilon پس از تکرار دورهای آموزشی، به شدت بزرگ می‌شود. این اپسیلون بزرگ عملاً هیچ تضمین واقعی و معناداری برای حفظ حریم خصوصی شرکت‌کنندگان فراهم نمی‌کند؛ به همین دلیل به آن Weak DP (حریم خصوصی تفاضلی ضعیف) می‌گویند.

ب) رویکرد Local Differential Privacy (LDP): در این روش، فرآیند تزریق نویز پیش از ارسال هرگونه اطلاعاتی به سرور، به صورت محلی و توسط خود کلاینت‌ها انجام می‌شود. در LDP، کلاینت‌ها برای آموزش مدل از الگوریتم‌هایی مانند DP-SGD استفاده می‌کنند که حریم خصوصی را در سطح رکوردهای داده (record-level) تأمین می‌کند. مزیت این روش آن است که کلاینت‌ها نیازی به اعتماد به سرور مرکزی برای حفظ حریم خصوصی خود ندارند.

رویکرد Central differential Privacy (CDP): در این روش، وظیفه ایجاد حریم خصوصی بر عهده سرور مرکزی است. سرور ابتدا نرم به‌روزرسانی‌های دریافتی از تمام کلاینت‌ها را محدود (clip) کرده، سپس آن‌ها را با یکدیگر تجمیع می‌کند و در گام آخر به این خروجی تجمیع‌شده، نویز گاوسی اضافه می‌کند. این رویکرد حریم خصوصی را در سطح کاربر (participant-level) تضمین می‌کند. اما پیش‌شرط آن این است که کلاینت‌ها باید به سرور اعتماد داشته باشند تا به‌روزرسانی‌های آن‌ها را به درستی و بدون نشت اطلاعات تجمیع کند.

ج) تفاوت بنیادین این دو مکانیزم در هدف‌گذاری و زمان اعمال نویز است. مکانیزم LDP حریم خصوصی را در سطح رکورد (Record-level) تأمین می‌کند؛ به این معنا که از افشای اطلاعات مربوط به یک داده یا رکورد خاص در داخل مجموعه داده‌های یک کلاینت جلوگیری می‌کند. اما در مقابل، مکانیزم CDP حریم خصوصی را در سطح کاربر یا شرکت‌کننده (Participant-level) تضمین می‌کند؛ یعنی پنهان می‌کند که آیا اساساً یک کلاینت مشخص در فرآیند آموزش مدل مشارکت داشته است یا خیر.

د) منظور از حمله‌ای که LDP در برابر آن ناکارآمد است، حمله property inference می‌باشد. از آنجا که CDP حریم خصوصی را در سطح Participant تضمین می‌کند، از نظر تئوری باید بتواند از نشت ویژگی‌های کلی مجموعه داده (property inference) یک کلاینت هم جلوگیری کند. اما در عمل، برای ایجاد این سطح گسترده از privacy، سرور مجبور است متناسب با کل حجم به‌روزرسانی‌های کلاینت‌ها، یک نويز گاوسی بسیار بزرگی را به مدل تجميع شده اضافه کند. این نويز بسیار بزرگ، بر سیگنال‌های یادگیری مفید غلبه کرده و باعث می‌شود مدل همگرا نشود یا دقت وظیفه اصلی (utility) به شدت سقوط کند.

ه) در این سناریو با تعداد کم کلاینت‌ها، استفاده از مکانیزم LDP توصیه می‌شود.

دلیل اول برای این انتخاب این است که بر اساس یافته‌های مقاله، در محیط‌هایی با تعداد شرکت‌کنندگان کم، مکانیزم CDP برای پنهان کردن اطلاعات یک کلاینت نیازمند تزریق نويز بسیار بالایی است که منجر به افت شدید utility می‌شود و عملاً مدل دقت لازم برای تشخیص‌های حساس پزشکی را از دست می‌دهد.


دلیل دوم این است که مکانیزم LDP به دلیل اعمال نويز در سطح رکوردها، عملکرد پایدارتری در تعداد کلاینت پایین دارد و به مدل اجازه می‌دهد تا همگرایی و دقت قابل قبولی را حفظ کند. نتایج تجربی مقاله ثابت کرده است که LDP با حفظ این utility، همچنان می‌تواند به شکلی مؤثر در برابر حملات خطرناکی مثل مسموم‌سازی مدل (backdoor) و membership inference دفاع کند.

بخش سوم: سؤالات پیاده‌سازی

زیربخش اول: آماده‌سازی داده‌ها

۱.۱- بارگذاری و بررسی اولیه داده

کد این بخش در فایل Q2.ipynb در فلدر Q2 موجود است و نتیجه به صورت زیر است:



شکل ۱۴ - ویژگی‌های اصلی دیتاست و چند نمونه از آن

مجموعه داده استفاده شده در این آزمایش‌ها FEMNIST است که شامل تصاویر سیاه‌وسفید ۲۸ در ۲۸ پیکسلی از اعداد و حروف دست‌نویس می‌باشد. ماهیت کلیدی این داده‌ها، ساختار مبتنی بر نویسنده و توزیع ناهمگون (Non-IID) آن‌هاست؛ به این معنی که داده‌ها بر اساس سبک منحصر به فرد دست‌خط هر شخص، در بین چندین سازمان پراکنده شده‌اند. این ناهمگونی، شرایط شبکه‌های فدرال در دنیای واقعی را به خوبی شبیه‌سازی می‌کند.

۱.۲- تعریف مجموعه‌های Member و Non-Member

کد این بخش در فایل Q2.ipynb در فلدر Q2 موجود است و نتیجه به صورت زیر است:

```
Member Subjects: 1798 (Images: 406368)
Non-Member Subjects: 1799 (Images: 407909)
```

شکل ۱۵ - تعداد نویسندگان عضو و غیرعضو به همراه تعداد تصاویر هر کدام


۱.۳- ایجاد ساختار Cross-Silo

در این روش پارتیشن‌بندی، داده‌های هر فرد (Subject) به جای تمرکز در یک گره، به صورت تصادفی بین ۱ تا ۳ سازمان از مجموع ۸ سیلوی موجود توزیع و قطعه‌قطعه می‌شود. این ساختار پراکنده دقیقاً معماری

یادگیری فدرال Cross-Silo در دنیای واقعی را شبیه‌سازی می‌کند که در آن رکوردهای اطلاعاتی یک شخص (مانند سوابق پزشکی یا مالی) در چندین نهاد یا پایگاه داده مختلف پخش شده است. این ویژگی برای مطالعه حملات استنتاج عضویت بسیار مناسب است، زیرا نشان می‌دهد که چگونه تجمیع این قطعات پراکنده در جریان آموزش فدرال می‌تواند توزیع داده‌های یک فرد کامل را در مدل سراسری افشا کند و به مهاجم اجازه دهد تا حضور یا عدم حضور آن شخص خاص را در کل سیستم فدراسیون تشخیص دهد.

۱.۴- تحلیل آماری و مصورسازی

کد این بخش در فایل Q2.ipynb در فلدر Q2 موجود است و نتیجه به صورت زیر است:



شکل ۱۶ - تحلیل‌های آماری و بصری سیلوها

۱.۵- بحث و نتیجه‌گیری

بر اساس نمودار میله‌ای و آمارهای ارائه‌شده، توزیع داده‌ها بین سازمان‌ها (سیلوها) به شکل نسبتاً متوازن و یکنواختی انجام شده است. هر یک از ۸ سازمان شرکت‌کننده، سهمی بین ۱۱.۸ درصد تا نهایتاً ۱۳.۶ درصد از کل تصاویر را در اختیار دارند که نشان می‌دهد هیچ سازمانی از نظر حجم داده‌ها برتری یا ضعف شدیدی نسبت به بقیه نداشته و بار اطلاعاتی به خوبی متعادل شده است.

داده‌های افراد (Subjects) عمدتاً بین چند سازمان مختلف پراکنده شده‌اند و تمرکز انحصاری در یک نقطه ندارند. همان‌طور که نمودار دایره‌ای به وضوح نشان می‌دهد، ۶۸ درصد از کاربران دارای داده‌هایی هستند که در بیش از یک سیلو پخش شده است و تنها ۳۲ درصد از آن‌ها صرفاً در یک سیلو واحد حضور دارند. این نوع پارتیشن‌بندی و تکه‌تکه شدن اطلاعات یک شخص، اجرای حملات استنتاج عضویت در سطح تک‌رکورد (Record-Level) را برای مهاجم دشوارتر می‌کند، زیرا ردهای اطلاعاتی فرد در گره‌های مختلف پخش شده‌اند. اما با این وجود، این ساختار حملات استنتاج در سطح کاربر (Subject-Level) را دشوارتر نمی‌کند؛ چرا که در فرآیند یادگیری فدرال، مدل سراسری در نهایت آپدیت‌های این قطعات پراکنده را تجمیع کرده و کل توزیع داده‌های آن شخص را یاد می‌گیرد، که این امر به مهاجم اجازه می‌دهد با بررسی مدل نهایی، حضور فرد را در شبکه تشخیص دهد.

زیربخش دوم: آموزش مدل فدرال

هایپرپارامترها به صورت زیر تنظیم شده‌اند:

```
# hyperparameters
num_rounds = 15
local_epochs = 3
batch_size = 64
learning_rate = 0.001
```

شکل ۱۷ – هایپرپارامترهای مدل


کد این بخش در فایل Q2.ipynb در فلدر Q2 موجود است و نتیجه به صورت زیر است:

```

Starting Federated Training (FedAvg):
Round 01/15 | Global Acc: 0.5271 | Global Loss: 1.6408
Round 02/15 | Global Acc: 0.8332 | Global Loss: 0.5227
Round 03/15 | Global Acc: 0.8520 | Global Loss: 0.4556
Round 04/15 | Global Acc: 0.8589 | Global Loss: 0.4272
Round 05/15 | Global Acc: 0.8627 | Global Loss: 0.4126
Round 06/15 | Global Acc: 0.8659 | Global Loss: 0.4031
Round 07/15 | Global Acc: 0.8687 | Global Loss: 0.3966
Round 08/15 | Global Acc: 0.8704 | Global Loss: 0.3912
Round 09/15 | Global Acc: 0.8706 | Global Loss: 0.3880
Round 10/15 | Global Acc: 0.8707 | Global Loss: 0.3868
Round 11/15 | Global Acc: 0.8722 | Global Loss: 0.3860
Round 12/15 | Global Acc: 0.8728 | Global Loss: 0.3843
Round 13/15 | Global Acc: 0.8737 | Global Loss: 0.3855
Round 14/15 | Global Acc: 0.8735 | Global Loss: 0.3848
Round 15/15 | Global Acc: 0.8736 | Global Loss: 0.3876

Final Global Model Accuracy on Member Test Set: 0.8736

```



شکل ۱۸ - عملکرد مدل در طول آموزش به همراه نمودارهای دقت و loss

در پیاده‌سازی این سیستم، مدل با استفاده از الگوریتم FedAvg در طی ۱۵ دور ارتباطی آموزش دیده است و با مشاهده نمودارها مشخص است که مدل به وضوح به همگرایی کامل رسیده است؛ به طوری که پس از یک جهش قابل توجه در دقت و افت شدید خطا در دور دوم، روند آموزش تثبیت شده و در نهایت دقت مدل جهانی روی مجموعه آزمون به ۸۷.۳۶ درصد می‌رسد. کیفیت و سرعت این همگرایی تحت تأثیر جمعیت صحیح پارامترها و تنظیمات متناسب آموزش محلی (مانند تعداد Epochها) در سیلوها بوده است.

مکانیزم تعامل به این صورت است که هر سازمان مدل را به صورت محلی روی داده‌های خود آموزش داده و سرور مرکزی در هر دور، به‌روزرسانی‌های ارسالی از تمام سیلوها را دریافت و به صورت میانگین‌گیری وزن‌دار جمع می‌کند تا مدل جهانی جدید شکل بگیرد. در این معماری، حفظ مرز دقیق و ایزوله بودن داده‌های Member از Non-Member به شدت حیاتی است؛ زیرا هدف نهایی حملات استنتاج عضویت، تمایز قائل شدن بین توزیع داده‌های استفاده‌شده در فدراسیون و داده‌های غایب در آموزش است. اگر این تفکیک به درستی رعایت نشود و مدل جهانی داده‌های غیرعضو را در طول آموزش ببیند، ارزیابی‌های حریم خصوصی کاملاً نامعتبر و بایاس‌دار شده و امکان سنجش دقیق حفظ حریم خصوصی اطلاعات از بین می‌رود.


MEMBERSHIP INFERENCE حملات ارزیابی سوم:

کد این بخش در فایل Q2.ipynb در فلدر Q2 موجود است و نتیجه به صورت زیر است:

```
Starting Membership Inference Attacks:
Round 01/15 | Subject Acc: 0.5000 | Record Acc: 0.5140
Round 02/15 | Subject Acc: 0.5000 | Record Acc: 0.5180
Round 03/15 | Subject Acc: 0.5000 | Record Acc: 0.5240
Round 04/15 | Subject Acc: 0.5400 | Record Acc: 0.5100
Round 05/15 | Subject Acc: 0.5800 | Record Acc: 0.5180
Round 06/15 | Subject Acc: 0.6000 | Record Acc: 0.5180
Round 07/15 | Subject Acc: 0.6400 | Record Acc: 0.5160
Round 08/15 | Subject Acc: 0.6100 | Record Acc: 0.5200
Round 09/15 | Subject Acc: 0.6600 | Record Acc: 0.5180
Round 10/15 | Subject Acc: 0.6200 | Record Acc: 0.5200
Round 11/15 | Subject Acc: 0.6900 | Record Acc: 0.5220
Round 12/15 | Subject Acc: 0.6400 | Record Acc: 0.5160
Round 13/15 | Subject Acc: 0.6500 | Record Acc: 0.5100
Round 14/15 | Subject Acc: 0.6400 | Record Acc: 0.5100
Round 15/15 | Subject Acc: 0.6500 | Record Acc: 0.5140
```

```
--- Subject-Level Attack (Loss-Across-Rounds) ---
Accuracy: 0.6500
Precision: 0.6271
Recall: 0.7400
F1-Score: 0.6789
```

```
--- Record-Level Attack (Baseline) ---
Accuracy: 0.5140
Precision: 0.5140
Recall: 0.5140
F1-Score: 0.5140
```



شکل ۱۹ - معیارهای ارزیابی حملات به همراه نمودار

بر اساس نتایج به دست آمده، حمله در سطح کاربر (Subject-Level Attack) با استفاده از روش Loss-Across-Rounds به شکل قابل توجهی موفق تر عمل کرده است. این حمله توانست به Accuracy معادل ۶۵ درصد و معیار F1-Score معادل ۶۷.۸۹ درصد دست یابد، در حالی که عملکرد حمله در سطح رکورد (Record-Level Attack) با دقت ۵۱.۴۰ درصد، کاملاً خنثی و در حد تصادفی (۵۰ درصد) باقی ماند.

دلیل اصلی این موفقیت آن است که حمله Subject-Level به جای بررسی یک خروجی ثابت، روند کاهش و تغییرات loss را در طول چندین راند متوالی از آموزش بررسی و ارزیابی می کند. این ارزیابی در طول

زمان، سیگنال بسیار قوی‌تری از حضور داده‌های یک شخص ارائه می‌دهد؛ در حالی که اثر یک عکس یا یک رکورد در میان حجم عظیم داده‌ها کمرنگ می‌شود و حمله Record-Level را با شکست مواجه می‌سازد.

این نتایج نشان می‌دهند که معماری یادگیری فدرال، به طور ذاتی یک لایه محافظتی نسبی برای داده‌های تکی و منفرد ایجاد می‌کند؛ به طوری که ریسک حریم خصوصی در سطح رکورد (Record-Level) بسیار پایین است و مدل اطلاعات یک تک‌نمونه را حفظ نمی‌کند. با این حال، همین معماری در برابر افشای اطلاعات در سطح کاربر آسیب‌پذیر است و ریسک حریم خصوصی در سطح کاربر (Subject-Level) بسیار بالاست. هنگامی که داده‌های مرتبط با یک شخص در فرآیند آموزش مشارکت داشته باشند، مدل به مرور زمان ویژگی‌ها و توزیع کلی مرتبط با آن فرد را به خاطر می‌سپارد و بنابراین ریسک حریم خصوصی در سطح کاربر بالا می‌رود.

زیربخش چهارم: دفاع مبتنی بر DIFFERENTIAL PRIVACY

۴.۱- دفاع پایه (DP-SGD / Record-Level DP)

کد این بخش در فایل Q2.ipynb در فلدر Q2 موجود است و نتیجه به صورت زیر است:

```

Starting Federated Training with Record-Level DP:
Round 01/15 | Cumulative Epsilon: 0.2613
Round 02/15 | Cumulative Epsilon: 0.5226
Round 03/15 | Cumulative Epsilon: 0.7838
Round 04/15 | Cumulative Epsilon: 1.0451
Round 05/15 | Cumulative Epsilon: 1.3064
Round 06/15 | Cumulative Epsilon: 1.5677
Round 07/15 | Cumulative Epsilon: 1.8290
Round 08/15 | Cumulative Epsilon: 2.0903
Round 09/15 | Cumulative Epsilon: 2.3515
Round 10/15 | Cumulative Epsilon: 2.6128
Round 11/15 | Cumulative Epsilon: 2.8741
Round 12/15 | Cumulative Epsilon: 3.1354
Round 13/15 | Cumulative Epsilon: 3.3967
Round 14/15 | Cumulative Epsilon: 3.6580
Round 15/15 | Cumulative Epsilon: 3.9192

--- Report parameters for Record-Level DP ---
Target Epsilon ( $\epsilon$ ): 4.0
Target Delta ( $\delta$ ): 1e-05
Clipping Norm: 1.0
Noise Multiplier ( $\sigma$ ): 0.9082
Global Model Accuracy (Utility): 0.5079

--- Attack Results on Record-Level DP Model ---
Record-Level Attack -> Accuracy: 0.5240 | F1-Score: 0.5240
Subject-Level Attack -> Accuracy: 0.4800 | F1-Score: 0.6119

```

شکل ۲۰ - عملکرد دفاع پایه

در پیاده‌سازی دفاع در سطح رکورد (Record-Level DP)، منطق اصلی این است که از حفظ شدن اطلاعات تک‌تک عکس‌ها توسط مدل در حین آموزش محلی جلوگیری کنیم. برای این کار، در هر مرحله از آموزش، ابتدا بزرگی تغییرات (گرادیان) مربوط به هر عکس به طور مستقل محاسبه شده و اگر از حد مجاز فراتر برود، روی عدد ۱ clip می‌شود تا هیچ تصویر منفردی تأثیر بیش از حدی روی یادگیری مدل نگذارد. سپس برای پنهان کردن ردپای اطلاعات، به این گرادیان‌های برش‌خورده نویز تصادفی با ضریب ۰.۹۰۸۲ (Noise Multiplier) اضافه می‌گردد. این clip و نویز، سطح حفاظت مستحکمی را با بودجه حریم خصوصی هدف، تضمین می‌کند. در طول ۱۵ راند آموزش فدرال، این بودجه به صورت تجمیعی و پله‌پله مصرف شده و در نهایت با روی عدد ۳.۹۱۹۲ متوقف می‌شود؛ در واقع در این مکانیزم توانستیم که با فدا کردن بخشی از کارایی مدل و کاهش دقت آن به ۵۰.۷۹ درصد، حملات استنتاج مهاجم را کاملاً خنثی کرده و دقت حمله را به سطح حدس تصادفی (حدود ۴۸ تا ۵۲ درصد) برسانیم.

۴.۲- دفاع پیشرفته (Subject-Level DP)

کد این بخش در فایل Q2.ipynb در فلدر Q2 موجود است و نتیجه به صورت زیر است:

```
Starting Federated Training with Subject-Level DP:
Round 01/15 | Cumulative Epsilon: 0.8925
Round 02/15 | Cumulative Epsilon: 1.3023
Round 03/15 | Cumulative Epsilon: 1.6257
Round 04/15 | Cumulative Epsilon: 1.9048
Round 05/15 | Cumulative Epsilon: 2.1550
Round 06/15 | Cumulative Epsilon: 2.3845
Round 07/15 | Cumulative Epsilon: 2.5984
Round 08/15 | Cumulative Epsilon: 2.7996
Round 09/15 | Cumulative Epsilon: 2.9906
Round 10/15 | Cumulative Epsilon: 3.1730
Round 11/15 | Cumulative Epsilon: 3.3480
Round 12/15 | Cumulative Epsilon: 3.5166
Round 13/15 | Cumulative Epsilon: 3.6796
Round 14/15 | Cumulative Epsilon: 3.8375
Round 15/15 | Cumulative Epsilon: 3.9909

--- Report parameters for Subject-Level DP ---
Target Epsilon ( $\epsilon$ ): 4.0
Target Delta ( $\delta$ ): 1e-05
Server Clipping Norm: 1.5
Calculated Noise Multiplier ( $\sigma$ ): 4.4922
Global Model Accuracy (Utility): 0.0181

--- Attack Results on Subject-Level DP Model ---
Record-Level Attack -> Accuracy: 0.5000 | F1-Score: 0.5000
Subject-Level Attack -> Accuracy: 0.4700 | F1-Score: 0.6294
```

شکل ۲۱ - عملکرد دفاع پیشرفته

در پیاده‌سازی دفاع پیشرفته (Subject-Level DP)، استراتژی محافظت از سطح هر نمونه‌ها (Record) به سطح مجموعه آپدیت‌های ارسال شده تغییر می‌کند. برخلاف روش قبلی که نویز روی عکس‌های منفرد در زمان آموزش محلی اعمال می‌شد، در اینجا فرآیند برش (با سقف clip ۱.۵) و تزریق نویز مستقیماً روی آپدیت‌های تجمیعی در سمت سرور انجام می‌گیرد. از آنجا که پنهان کردن توزیع داده‌های یک فرد (Subject) بسیار دشوارتر از پنهان کردن یک تک‌عکس است، سیستم مجبور است نویز بسیار سنگین‌تری (با ضریب $\sigma \approx 4.4922$) را به مدل تزریق کند تا بودجه حریم خصوصی همچنان در سقف ۴ باقی بماند.

این حجم عظیم از نویز توانست اثر توزیع داده‌های کاربران را در مدل کاملاً محو کند و دقت حمله Subject-Level را به ۴۷ درصد (پایین‌تر از حدس تصادفی) کاهش دهد که نشان‌دهنده موفقیت کامل این مکانیزم دفاعی است. با این حال، این نویز شدید، کارایی و utility مدل را عملاً از بین برده و دقت نهایی آن را به ۱.۸۱ درصد رساند. این نتیجه نشان می‌دهد که تضمین حریم خصوصی در سطح کلان Subject، نیازمند فدا کردن کامل دقت و کاربرد مدل است.

۴.۳- آزمایش حساسیت

کد این بخش در فایل Q2.ipynb در فلدر Q2 موجود است و نتیجه به صورت زیر است:

```
--- Baseline (Section 4.1) ---
Parameters: Rounds=15 | Clipping Norm=1.0 | Sigma (Noise)=0.9
Final Calculated Epsilon ( $\epsilon$ ): 1.2588

--- Experiment 1: Double Sigma ---
Parameters: Rounds=15 | Clipping Norm=1.0 | Sigma (Noise)=1.8
Final Calculated Epsilon ( $\epsilon$ ): 0.3419

--- Experiment 2: Halve Clipping Norm ---
Parameters: Rounds=15 | Clipping Norm=0.5 | Sigma (Noise)=0.9
Final Calculated Epsilon ( $\epsilon$ ): 1.2588

--- Experiment 3: Double Rounds ---
Parameters: Rounds=30 | Clipping Norm=1.0 | Sigma (Noise)=0.9
Final Calculated Epsilon ( $\epsilon$ ): 1.5495
```

شکل ۲۲ - نتایج آزمایش‌های حساسیت

نتایج به‌دست‌آمده کاملاً با تئوری‌های نظری حریم خصوصی تفاضلی سازگار است و انتظارات نظری را به زیبایی برآورده می‌کند. در آزمایش اول، با دو برابر کردن ضریب نویز (σ)، مقدار اپسیلون نهایی به شدت کاهش یافت (از ۱.۲۵۸۸ به ۰.۳۴۱۹)؛ این رفتار کاملاً منطقی است، زیرا تزریق نویز بیشتر به معنای حفاظت قوی‌تر از حریم خصوصی و در نتیجه نشت اطلاعات (اپسیلون) کمتر است.

در آزمایش دوم، با نصف کردن حد clipping، مقدار اپسیلون هیچ تغییری نکرد و همان ۱.۲۵۸۸ باقی ماند. این اتفاق دقیقاً مطابق تئوری است، زیرا در کتابخانه‌هایی مثل Opacus، میزان نویز واقعی اعمال‌شده برابر با حاصل‌ضرب ضریب نویز در حد برش (نویز $\sigma \times C$) است؛ بنابراین وقتی حد برش را نصف می‌کنیم، هم حساسیت گرادپان‌ها و هم نویز مطلق به یک نسبت مساوی کاهش می‌یابند و نسبت آن‌ها ثابت می‌ماند، در نتیجه سطح حریم خصوصی (ϵ) ثابت می‌ماند.

در نهایت، در آزمایش سوم با دو برابر شدن تعداد راندهای آموزش، مقدار اپسیلون افزایش یافت (به ۱.۵۴۹۵ رسید) که دلیل آن نشت بیشتر اطلاعات در اثر دفعات استفاده‌ی بیشتر از داده‌های حساس در طول فرآیند آموزش است.

۴.۴- مقایسه و تحلیل Trade-off

کد این بخش در فایل Q2.ipynb در فلدر Q2 موجود است و نتیجه به صورت زیر است:

--- Summary & Comparison of Defenses ---

Defense Type	Epsilon Budget	Noise Multiplier	Model Utility (Acc)	Record-Level Attack Acc	Subject-Level Attack Acc
Baseline (No DP)	Infinity	0.0000	0.8736	0.5140	0.6500
Record-Level DP	4.00	0.9082	0.5079	0.5240	0.4800
Subject-Level DP	4.00	4.4922	0.0181	0.5000	0.4700

شکل ۲۳ - جدول مقایسه عملکرد دفاع‌ها

دفاع Record-Level در این آزمایش‌ها تعادل (Trade-off) به مراتب بهتری بین حفظ حریم خصوصی و فایده‌ی مدل ایجاد کرده است؛ زیرا توانسته با حفظ دقت نسبی حدود ۵۰ درصد برای مدل سراسری، نرخ موفقیت حمله را در سطح کاربر تا مرز حدس تصادفی (۴۸ درصد) پایین بیاورد، در حالی که مکانیزم Subject-Level با سقوط دقت به ۱.۸۱ درصد، عملاً کارایی و ارزش سیستم را نابود کرده است.

با این حال، از منظر معماری و تئوری، دفاع Subject-Level برای مقابله با مسئله Subject Membership انتخاب اصولی‌تر و دقیق‌تری محسوب می‌شود. علت این برتری، آن است که مکانیزم Record-Level صرفاً پنهان ماندن یک تک‌داده را تضمین می‌کند و اگر کاربری رکوردهای متعددی در فدراسیون داشته باشد، ویژگی‌های کلی داده‌های او همچنان می‌تواند توسط مدل الگوبرداری و حفظ شود؛ اما دفاع Subject-Level با اعمال برش و تزریق نویز روی برآیند کل آپدیت‌ها در سمت سرور، به صورت ریاضی و قطعی تضمین می‌دهد که حضور یا غیبت تمامی داده‌های یک شخص خاص، در توزیع نهایی مدل قابل تشخیص نباشد.


پیوست الف - اظهارنامه استفاده از هوش مصنوعی

اعلام می‌کنم که اثبات‌ها، استدلال‌های مفهومی، تفسیرها و متن گزارش این تمرین، کار خودم است. از هوش مصنوعی فقط در همان حدی استفاده کرده‌ام که سیاست صفحه نخست اجازه می‌دهد؛ جزئیاتش هم در جدول زیر آمده است.

ابزار	برای چه کاری استفاده شد
جمناي	در ابتدای هر دو سوال، سوالاتی درباره مفاهیم پایه‌ای که در اسلایدها بود و به خوبی متوجه نشده بودم پرسیدم.
جمناي	در چندین سوال، متن سوال را به خوبی متوجه نشدم و از جمناي کمک گرفتم.
جمناي	برای تصحیح و بهبود نگارش پاسخ اکثر سوالات کمک گرفتم.
جمناي	در چندین سوال که واقعا ایده‌ای به ذهنم نمی‌رسید، در حد ایده کمک گرفتم.
جمناي	در مورد کتابخانه‌ها و توابع آماده مورد نیاز در کد کمک گرفتم.
جمناي	در چند مورد به باگ‌هایی در کد برخورد کردم که خودم نتوانستم رفع کنم و کمک گرفتم.
جمناي	در چند مورد از رسم نمودارها از آن کمک گرفتم.
جمناي	در دو مورد، نتایجی که از اجرای کد گرفتم برایم منطقی نبود و در مورد توجیه آنها کمک گرفتم.

نام و نام خانوادگی: سیدمحمدجواد شریفی

امضا / تاریخ: ۱۴۰۵ / ۵ / ۳



۱- مقالات:

- Kusner et al., 2017; "Counterfactual Fairness"
- Kilbertus et al., 2017; "resolving"
- Dissecting Racial Bias in an Algorithm Used to (Obermeyer et al., 2019: Manage the Health of Populations)
- Kearns et al., 2018; "Fairness Gerrymandering"
- Liu et al., 2018; "Delayed Impact of Fair Machine Learning"
- Local and Central Differential Privacy for Robustness
- Subject Membership Inference Attacks in Federated Learning

۲- اسلایدهای درس:

- 22- Introduction to Fairness
- 23-Fairness-criteria
- 25-Introduction to Privacy
- 26-Privacy-2